

Dynamiques sphériques de Transformers

Dossier théorique et numérique complet

Équilibres, polygones, cycles, MLP, chaos, multi-têtes, grande dimension, champ moyen, entraînement et poids variables

Version du 16 août 2026

Volume I — Attention sans MLP, pages 2 à 17. Condition nécessaire et suffisante de tous les équilibres, couche finie et temps continu, réduction spectrale–Gram dans le cas $Q^T K = V = V^T$, formes polygonales, comparaison précise avec Altafini et cycle interne stable produit par l’attention seule lorsque score et valeur sont déliés.

Volume II — Bloc sériel attention puis MLP, pages 18 à 37. Équations exactes de tous les points fixes et cycles, taxonomie des quatre familles, audit jusqu’à des couches 4 096 fois plus faibles, cycles continus, chaos et hyperchaos, cartes multi-têtes, limite à beaucoup de tokens, autres noyaux, observables, entraînement du MLP, première étape de Muon et poids OU lents.

Échelle de validation. Le dossier s’appuie sur 214 528 modèles tirés indépendamment, 2 844 160 trajectoires initiales, plus de 10^{11} mises à jour token–couche dans l’audit de petite couche, des intégrations continues indépendantes, des spectres complets de perturbations et des contrôles frais allant jusqu’à 16 tokens.

Règle de lecture. Les équations encadrées sont des identités ou conditions exactes. Les tableaux numériques sont des observations reproductibles sur les protocoles indiqués. Les idées MaxCut, répliques, résolution universelle de problèmes difficiles et conception arbitraire d’équilibres sont conservées comme pistes et ne sont pas présentées comme des théorèmes.

Attention sphérique sans MLP : équilibres exacts, multistabilité et cycle interne stable

Rapport théorique et numérique reproductible

Soumission anonyme

Version du 16 août 2026

Résumé

Nous étudions une pile de couches réduite à son mécanisme d'attention : aucun réseau MLP n'est présent. Chaque jeton est un point de norme un et chaque couche le déplace, puis le renormalise. Le premier résultat est une condition nécessaire et suffisante, valable pour tout nombre de jetons, toute dimension et toutes matrices de score et de valeur : à l'équilibre, la moyenne transportée vue par chaque jeton doit être exactement parallèle à ce jeton. Nous donnons sa version pour une couche finie, sa réduction par groupes, sa linéarisation exacte et, dans le cas lié $Q^T K = V = V^T$, une description complète par matrices de produits scalaires. Cette description contient les consensus, les séparations en deux signes, les formes à plusieurs sommets, les familles continues et les mélanges de directions propres.

Le second résultat sépare trois objets souvent confondus : un cycle de trois ou quatre couches, un cycle continu dont le nombre de couches par tour croît comme l'inverse de la force d'une couche, et une simple rotation rigide. Dans le cas lié symétrique, une quantité scalaire augmente strictement et interdit tout cycle continu non constant. En revanche, lorsque les matrices de score et de valeur sont indépendantes et que le transport par V n'est pas réciproque, l'attention seule produit un cycle interne stable à trois jetons. Son temps de retour est 9,12 dans l'unité de profondeur de l'audit ; ses deux taux de contraction transverses sont proches de $-0,457$ et $-0,459$; 128 perturbations reviennent vers la même boucle. Pour sept forces de couche, dyadiques et non dyadiques, le nombre de couches par tour suit une pente 1,012 en échelle logarithmique. Nous n'avons, à ce stade, certifié ni chaos produit par l'attention seule ni inventaire exhaustif des cycles dans le cas non réciproque.

Lecture concrète. Le message en une phrase est le suivant : sans MLP, l'attention symétrique peut avoir beaucoup de destinations stables mais elle finit par s'arrêter ; l'attention générale peut, à elle seule, maintenir une boucle stable où les distances entre jetons changent indéfiniment.

Table des matières

1	Question étudiée et réponse courte	3
2	Le modèle, depuis une couche jusqu'au temps continu	3
3	La condition finale de tous les équilibres	4
4	Cas lié symétrique : une description complète	5
5	Quand un équilibre attire-t-il les trajectoires ?	7
6	Cycles : trois objets qu'il faut séparer	8
7	Pourquoi la symétrie interdit les cycles continus	9
8	Expérience centrale : un cycle stable produit par l'attention seule	10
9	Comparaison exacte avec Altafini et Kuehn–Yoon	12
10	Ce qui est nouveau, dit simplement	14
11	Conclusion	14
A	Preuves complémentaires	14
B	Jacobienne exacte sur le cercle	15
C	Partage bipolaire déséquilibré	15
D	Reproductibilité et traçabilité des affirmations	16

1 Question étudiée et réponse courte

Une couche Transformer usuelle contient au moins une attention, une connexion résiduelle, une normalisation et un MLP [5]. Nous retirons ici complètement le MLP. Il reste une question très précise : que peuvent faire les jetons lorsqu'on répète uniquement l'attention et la normalisation ?

Les travaux de Geshkovski et collaborateurs ont montré que cette lecture en profondeur comme une dynamique de particules explique la formation de groupes [2, 3]. Altafini a classé quatre formes d'équilibre et mis en évidence leur coexistence [1]. Kuehn et Yoon ont ensuite isolé un cas plus contraint, $Q^\top K = V = V^\top$, dans lequel les directions propres de V organisent la destination [4]. Notre rapport réunit ces points de vue, ferme l'équation générale des équilibres et ajoute l'étude expérimentale des cycles sans MLP.

Les réponses sont :

1. une configuration est arrêtée si et seulement si chaque jeton reçoit une somme qui pointe exactement dans sa direction ou dans la direction opposée ; la normalisation enlève alors la partie radiale et aucun angle ne change ;
2. une forme visuellement polygonale n'est pas nécessairement un « équilibre polygonal » au sens d'Altafini : ce nom y désigne seulement le cas plus étroit où la somme reçue est nulle ;
3. si score et valeur sont la même matrice symétrique, aucun cycle continu stable ne peut exister ;
4. si l'on défait cette égalité, l'attention seule peut soutenir un cycle interne stable ; nous en donnons un exemple explicite et reproductible ;
5. un cycle de période trois couches observé à grande force n'est pas la même chose qu'un cycle continu. Le second demande de plus en plus de couches lorsque chaque couche devient plus faible.

2 Le modèle, depuis une couche jusqu'au temps continu

2.1 Ce que représentent les symboles

Il y a n jetons. Le jeton i est un vecteur $x_i \in \mathbb{R}^d$ de norme un. Il vit donc sur la sphère $\mathbb{S}^{d-1}$. Deux matrices suffisent :

- $S = Q^\top K$ décide qui regarde qui ;
- V décide quel vecteur est effectivement transporté.

Le nombre $\beta \geq 0$ règle la netteté du choix. Pour $\beta = 0$, tous les jetons sont pondérés de la même façon. Lorsque β augmente, les différences de scores comptent davantage. Pour une configuration $X = (x_1, \dots, x_n)$, posons

$$s_{ij}(X) = x_i^\top S x_j, \quad (1)$$

$$a_{ij}(X) = \frac{\exp(\beta s_{ij}(X))}{\sum_{k=1}^n \exp(\beta s_{ik}(X))}, \quad (2)$$

$$y_i(X) = \sum_{j=1}^n a_{ij}(X) V x_j. \quad (3)$$

a_{ij} est le poids donné par i à j , et y_i est la somme reçue par i après le transport par V .

2.2 Une couche finie

Sans MLP, la couche résiduelle normalisée est exactement

$$x_i^+ = \frac{x_i + hy_i(X)}{\|x_i + hy_i(X)\|}, \quad i = 1, \dots, n, \quad (4)$$

où $h > 0$ est la force d'une couche. Cette normalisation sur la sphère est une version idéalisée de RMSNorm [6].

2.3 Beaucoup de couches faibles

Écrivons

$$P_x = I - xx^\top.$$

$P_x z$ garde seulement la partie de z qui change la direction de x ; la partie parallèle à x changerait seulement sa longueur et sera supprimée par la normalisation. Le développement de (4) donne

$$x_i^+ = x_i + hP_{x_i}y_i(X) + O(h^2).$$

Si le nombre de couches croît pendant que h décroît, la limite est

$$\boxed{x_i = P_{x_i}y_i(X) = y_i(X) - (x_i^\top y_i(X))x_i.} \quad (5)$$

La norme reste égale à un car $x_i^\top \dot{x}_i = 0$.

Sur le cercle, on écrit $x_i = (\cos \theta_i, \sin \theta_i)$ et $t_i = (-\sin \theta_i, \cos \theta_i)$. L'équation devient un seul nombre par jeton :

$$\dot{\theta}_i = \sum_{j=1}^n a_{ij}(\theta) t_i^\top V x_j. \quad (6)$$

Toutes les expériences de cycle de ce rapport utilisent cette équation à trois jetons.

3 La condition finale de tous les équilibres

Théorème 3.1 (Condition nécessaire et suffisante, matrices générales). *Une configuration $X \in (\mathbb{S}^{d-1})^n$ est un équilibre de (5) si et seulement si, pour chaque jeton i ,*

$$\boxed{y_i(X) = \lambda_i x_i, \quad \lambda_i = x_i^\top y_i(X).} \quad (7)$$

De façon équivalente, sans dénominateur softmax,

$$\boxed{\sum_{j=1}^n e^{\beta x_i^\top S x_j} [V x_j - (x_i^\top V x_j) x_i] = 0, \quad i = 1, \dots, n.} \quad (8)$$

Démonstration. Le champ est $P_{x_i}y_i$. Il est nul exactement lorsque y_i appartient à la droite portée par x_i . Le coefficient de cette colinéarité est son produit scalaire avec x_i . Enfin, le dénominateur du softmax est strictement positif ; le multiplier ou le supprimer ne change donc pas l'égalité à zéro. $\square$

Lecture concrète. Il n'est pas nécessaire que la somme reçue soit nulle. Elle peut être grande. Il suffit qu'elle pousse exactement vers le centre ou vers l'extérieur le long du rayon du jeton. La renormalisation efface cette poussée radiale. C'est la raison simple pour laquelle des formes à plusieurs sommets peuvent être stables.

3.1 La condition exacte pour une couche finie

Proposition 3.2 (Point fixe de la couche). *Supposons $x_i + hy_i \neq 0$. La couche (4) laisse x_i inchangé si et seulement si*

$$P_{x_i} y_i = 0 \quad \text{et} \quad 1 + h\lambda_i > 0, \quad \lambda_i = x_i^\top y_i. \quad (9)$$

La première condition est la même que pour le temps continu. La seconde est propre à une couche finie : si $1 + h\lambda_i < 0$, la normalisation retourne le point antipodal $-x_i$; si $1 + h\lambda_i = 0$, elle tente de normaliser le vecteur nul.

3.2 Réduction exacte lorsque plusieurs jetons coïncident

Supposons que la configuration contienne seulement q positions distinctes $w_1, \dots, w_q$, répétées respectivement $r_1, \dots, r_q$ fois. Alors (8) devient le système fini

$$\sum_{b=1}^q r_b e^{\beta w_a^\top S w_b} [V w_b - (w_a^\top V w_b) w_a] = 0, \quad a = 1, \dots, q. \quad (10)$$

Ce n'est pas une approximation. On a seulement regroupé des termes identiques. Pour une instance fixée, (10) donne une procédure exhaustive : énumérer les partitions $r_1 + \dots + r_q = n$, résoudre les équations, puis retirer les copies obtenues par permutation.

3.3 Pourquoi le mot « polygone » a créé une confusion

Altafini [1] emploie quatre noms. La distinction utile est résumée dans le [table 1](#).

Table 1: Les quatre noms d'Altafini, exprimés avec la somme y_i de (3). Les deux dernières lignes couvrent toutes les formes non colinéaires.

Nom	Configuration	Condition reçue
Consensus	tous les x_i sont égaux à une direction propre de V	$y_i \parallel x_i$
Consensus bipolaire	chaque x_i vaut u ou $-u$, avec u propre	$y_i \parallel x_i$
Polygonal	plusieurs directions, et aucune sortie	$y_i = 0$ pour tout i
Clustering	tout autre équilibre, avec ou sans jetons coïncidents	$y_i = \lambda_i x_i$, au moins un $\lambda_i \neq 0$

Ainsi, « les points dessinent un triangle » est une description visuelle. « Polygonal » au sens du théorème d'Altafini est une condition algébrique beaucoup plus étroite. Un triangle dont les trois sorties sont non nulles et radiales appartient à sa quatrième classe. L'instabilité des sorties nulles ne dit rien contre la stabilité de ce triangle.

4 Cas lié symétrique : une description complète

Nous imposons maintenant

$$S = V = V^\top. \quad (11)$$

C'est exactement l'hypothèse de Kuehn–Yoon [4]. Elle est plus forte que celle d'Altafini : Altafini suppose V symétrique avec une valeur propre positive dominante simple, mais ne demande pas que $Q^\top K$ soit symétrique ni égal à V .

Écrivons les jetons comme les lignes d'une matrice $X \in \mathbb{R}^{n \times d}$ et posons

$$H = XVX^\top, \quad R = \exp_o(\beta H),$$

où l'exponentielle est appliquée entrée par entrée. Définissons

$$M = \text{Diag}(\text{diag}(RH)).$$

Théorème 4.1 (Équation vectorielle complète). *Sous (11),*

$$X \text{ est un équilibre} \iff RXV = MX, \text{quad} \text{diag}(XX^\top) = \mathbf{1}. \quad (12)$$

Cette formule est déjà nécessaire et suffisante. La suivante retire les rotations qui ne changent pas le problème.

Théorème 4.2 (Description spectrale par produits scalaires). *Soient $\lambda_1^*, \dots, \lambda_s^*$ les valeurs propres distinctes de V , de multiplicités $m_1, \dots, m_s$. Écrivons la partie de X dans chaque espace propre sous la forme $C_\alpha \in \mathbb{R}^{n \times m_\alpha}$ et posons $G_\alpha = C_\alpha C_\alpha^\top$. Modulo les rotations internes aux espaces propres, les équilibres sont exactement les familles (G_α) satisfaisant*

$$\begin{aligned} &G_\alpha \succeq 0, \text{quad} \text{rang } G_\alpha \leq m_\alpha, \\ &\sum_{\alpha=1}^s \text{diag } G_\alpha = \mathbf{1}, \\ &H = \sum_{\alpha=1}^s \lambda_\alpha^* G_\alpha, \quad R = \exp_o(\beta H), \\ &M = \text{Diag}(\text{diag}(RH)), \\ &(\lambda_\alpha^* R - M)G_\alpha = 0, \quad \alpha = 1, \dots, s. \end{aligned} \quad (13)$$

La preuve, donnée en [appendix A](#), consiste seulement à projeter (12) sur chaque espace propre puis à factoriser les matrices G_α . Le système (13) est une caractérisation complète, pas une liste de formes choisies à l'avance.

4.1 Toutes les familles universelles contenues dans la condition

Le [table 2](#) donne les branches qui existent sans résoudre numériquement un cas particulier.

Table 2: Familles exactes sans MLP sous l'hypothèse liée symétrique.

Situation	Tous les équilibres ou familles immédiatement garantis
$V = 0$	toute configuration de $(\mathbb{S}^{d-1})^n$
Un jeton	toutes les sphères unités contenues dans les espaces propres de V
Consensus	$x_1 = \dots = x_n = u$ pour toute direction propre unitaire u
Une droite propre	tout motif $x_i \in \{u, -u\}$
Noyau de V	toute configuration contenue dans $\ker V$; des ajouts mixtes sont possibles si la sortie active s'annule
Un espace propre multiple	simplexes réguliers, polygones réguliers, hypercubes et autres orbites symétriques, avec multiplicités compatibles
Plusieurs espaces propres	branches mixtes, symétriques ou asymétriques, résolues par (13) ou (10)

Il n'existe donc pas de liste finie valable pour tout n, d, V : si $V = 0$, chaque point est un équilibre ; si une valeur propre est multiple, des familles continues apparaissent. La bonne notion de « tous les équilibres » est la condition constructive (13).

4.2 Classification entièrement explicite lorsque $\beta = 0$

À $\beta = 0$, les poids valent tous $1/n$. Posons

$$z = V \sum_{j=1}^n x_j.$$

Théorème 4.3 (Tous les équilibres à attention uniforme). *Pour une matrice V quelconque, une configuration est un équilibre si et seulement si l'une des deux situations suivantes se produit :*

1. $z = 0$; toute configuration telle que $V \sum_j x_j = 0$ convient ;
2. $z \neq 0$; tous les jetons valent u ou $-u$, leur somme signée est non nulle, et u est un vecteur propre réel de V associé à une valeur propre non nulle.

Cette classification montre à la fois la richesse et la fragilité du cas uniforme. Avec une matrice symétrique, il s'agit d'une dynamique d'énergie. Avec une matrice non symétrique, une rotation peut subsister même si les poids ne changent jamais.

4.3 Une famille mixte exacte à trois groupes

Soient $Vu = au$, $Vv = bv$, avec $u \perp v$. Prenons m copies de u , k copies de $qu + \sqrt{1-q^2}v$ et k copies de $qu - \sqrt{1-q^2}v$. Cette forme est un équilibre exactement lorsque

$$q \left[(a-b)e^{\beta[b+(a-b)q^2]} + (a+b)e^{\beta[-b+(a+b)q^2]} \right] + a \frac{m}{k} e^{\beta a q} = 0. \quad (14)$$

Cette seule équation produit des branches qui utilisent simultanément deux directions propres. Elle explique pourquoi « choisir une seule valeur propre » ne suffit pas à décrire toutes les destinations.

5 Quand un équilibre attire-t-il les trajectoires ?

La condition (8) dit où la dynamique peut s'arrêter. La stabilité dit ce qui se passe après une petite erreur de position.

Soit δx_i une petite variation perpendiculaire à x_i . Définissons

$$\delta s_{ij} = \delta x_i^\top S x_j + x_i^\top S \delta x_j, \quad (15)$$

$$\delta a_{ij} = \beta a_{ij} \left(\delta s_{ij} - \sum_k a_{ik} \delta s_{ik} \right), \quad (16)$$

$$\delta y_i = \sum_j a_{ij} V \delta x_j + \sum_j \delta a_{ij} V x_j. \quad (17)$$

À un équilibre $y_i = \lambda_i x_i$, la variation tangentielle du champ est

$$\delta \dot{x}_i = P_{x_i} \delta y_i - \lambda_i \delta x_i. \quad (18)$$

Ces lignes donnent la matrice de stabilité exacte pour toutes matrices S, V . L'équilibre attire localement si toutes ses valeurs propres tangentielles ont une partie réelle strictement négative. Une valeur nulle peut simplement correspondre à une famille continue obtenue par rotation ; elle doit alors être retirée avant de conclure.

5.1 Directions propres pures dans le cas lié symétrique

Pour un consensus $x_i = u$ sur une valeur propre λ_p , la condition locale est particulièrement simple :

$$\lambda_p > 0, \text{quad} \lambda_k < \lambda_p \quad (k \neq p). \quad (19)$$

Le consensus stable utilise donc la plus grande valeur propre positive simple.

Pour un partage équilibré entre u et $-u$, les seuils sont :

$$\lambda_p > 0 : \quad \lambda_k < \lambda_p \tanh(\beta \lambda_p) \quad \text{pour tout } k \neq p, \quad (20)$$

$$\lambda_p < 0 : \quad \lambda_p < \lambda_k < \lambda_p \tanh(\beta \lambda_p) \quad \text{pour tout } k \neq p. \quad (21)$$

Le second cas sélectionne nécessairement la valeur propre la plus négative. Les formules pour un partage déséquilibré sont données en [appendix C](#).

5.2 Un triangle stable qui n'est pas « polygonal » au sens d'Altafini

Pour $V = S = \text{Diag}(2, -3)$, $\beta = 1,5$ et trois jetons, la recherche de racines trouve la configuration d'angles, arrondie ici,

$$(0, 1,546889, 4,736296).$$

Son taux linéaire le moins contractant vaut $-0,9144$ et le résidu calculé avant arrondi est $1,3 \times 10^{-15}$. Surtout, les longueurs des trois sorties non normalisées valent environ 40,27, 269,79 et 269,79 : elles ne sont pas nulles. Elles pointent radialement. Ce triangle est donc stable et appartient à la classe « clustering » d'Altafini, pas à sa classe « polygonal ».

La recherche multi-départ de petits systèmes donne le [figure 1](#). Deux graines indépendantes retrouvent exactement les mêmes ensembles après retrait des permutations et du changement de signe global.




Figure 1: Catalogue sans MLP pour $V = S$ symétrique en dimension deux. Les spectres sont $(2, -3)$ avec $\beta = 1,5$, $(-0,4, -4)$ avec $\beta = 0,03$, et $(3, 2)$ avec $\beta = 1,5$. Les nombres au second niveau des étiquettes sont les nombres de jetons. La recherche numérique découvre les branches ; la complétude théorique vient de (13), pas du nombre de départs.

6 Cycles : trois objets qu'il faut séparer

6.1 Cycle court d'une couche finie

Un cycle de période p de la couche est une suite de p configurations distinctes qui revient exactement au départ après p applications de (4). Cet objet dépend de la force h .

Lemme 6.1 (Un nombre fixe de couches ne survit pas tel quel). *Si la couche satisfait $F_h(X) = X + hf(X) + O(h^2)$ et si p reste fixe lorsque $h \rightarrow 0$, alors toute limite d'un cycle de période p vérifie $f(X) = 0$.*

En effet, $F_h^p(X) = X + phf(X) + O(h^2)$. Un cycle de trois couches peut donc se contracter vers un équilibre quand on rend les couches faibles. Il ne prouve pas l'existence d'une boucle en temps continu.

6.2 Cycle continu

Un cycle continu est une boucle parcourue en un temps $T > 0$. Une couche de force h n'en parcourt qu'une fraction. Le nombre de couches par tour doit donc croître comme T/h . C'est la signature mesurée dans le [figure 4](#).

6.3 Rotation rigide et cycle interne

Si tous les produits scalaires $x_i^\top x_j$ restent constants pendant que l'ensemble tourne, la forme n'évolue pas : c'est une rotation rigide. Dans un cycle interne, au moins une distance entre jetons change puis revient. Cette seconde situation est plus forte.

Un exemple analytique montre déjà que l'attention sans MLP peut tourner. Prenons un seul jeton sur le cercle, $S = 0$ et

$$V = \omega \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

Alors $\dot{x} = Vx$ et le jeton tourne avec période $2\pi/|\omega|$. Cette rotation est neutre : elle ne prouve pas qu'une boucle attire les perturbations. L'expérience de la [section 8](#) établit précisément ce point plus difficile.

7 Pourquoi la symétrie interdit les cycles continus

Sous $S = V = V^\top$ et pour $\beta > 0$, définissons

$$E_\beta(X) = \frac{1}{2\beta} \sum_{i,j=1}^n \exp(\beta x_i^\top V x_j). \quad (22)$$

Si $Z_i = \sum_j \exp(\beta x_i^\top V x_j)$, un calcul direct donne

$$\frac{dE_\beta}{dt} = \sum_{i=1}^n Z_i \|\dot{x}_i\|^2 \geq 0. \quad (23)$$

La quantité augmente strictement dès qu'un jeton bouge. Une trajectoire fermée devrait revenir à sa valeur initiale de E_β , ce qui est impossible sauf si elle est déjà arrêtée. Ce mécanisme est la structure de gradient pondéré utilisée par Kuehn–Yoon [\[4\]](#).

À $\beta = 0$, la même conclusion vaut avec

$$\Phi(X) = \frac{1}{2n} \left(\sum_i x_i \right)^\top V \left(\sum_j x_j \right).$$

Lecture concrète. La symétrie importante n'est pas seulement « V est symétrique ». Il faut, pour cette preuve, que la matrice qui calcule les scores soit la même que celle qui transporte les valeurs : $S = V = V^\top$. Si S et V sont indépendantes, l'argument disparaît.

Sur le cercle à $\beta = 0$, l'écart à la réciprocité se voit exactement dans

$$\frac{\partial \dot{\theta}_i}{\partial \theta_j} - \frac{\partial \dot{\theta}_j}{\partial \theta_i} = \frac{1}{n} t_i^\top (V - V^\top) t_j. \quad (24)$$

La partie antisymétrique de V fournit donc une circulation. À $\beta > 0$, la normalisation ligne par ligne des poids ajoute des termes supplémentaires. Même lorsque les dérivées croisées ordinaires ne coïncident pas, le cas $S = V = V^\top$ reste sans cycle grâce à la métrique pondérée de (23). Ce détail évite de confondre « gradient euclidien » et « quantité monotone ».

8 Expérience centrale : un cycle stable produit par l'attention seule

8.1 Paramètres explicites

Le modèle utilise trois jetons sur le cercle, aucun MLP, et

$$S = \begin{pmatrix} 1,112495 & 1,768642 \\ -2,540753 & 3,294286 \end{pmatrix}, \quad V = \begin{pmatrix} -1,809502 & 1,419182 \\ -1,827949 & -3,611608 \end{pmatrix}, \quad (25)$$

avec $\beta = 1,110063$. L'audit mesure la profondeur avec une échelle $\rho = 0,551488$: son équation est $\dot{\theta}_i = \rho \sum_j a_{ij} t_i^\top V x_j$. Absorber ρ dans le temps ramène exactement à (6).

Ce modèle a été isolé par ablation d'un candidat provenant d'un écran plus large avec MLP. Après suppression de tous les paramètres MLP, le cycle reste présent. Le MLP seul, avec l'attention supprimée, converge au contraire vers un point fixe. Cette sélection du modèle doit être gardée en tête : elle démontre l'existence d'un cycle d'attention, pas sa fréquence dans une loi aléatoire de matrices.

8.2 La forme change pendant le tour

La réintégration indépendante par Runge–Kutta d'ordre quatre, avec pas 0,005, donne un temps de retour $T = 9,12$ en profondeur normalisée, soit 5,030 dans le temps de (6) après absorption de ρ . Le résidu de retour au quantile 90% est $1,56 \times 10^{-3}$ radian.

Les trois produits scalaires entre paires varient chacun de $-0,8002$ à $-0,0551$. La forme change donc fortement. Les poids envoyés par le jeton 1 vers les jetons 1, 2 et 3 parcourent respectivement les intervalles

$$[0,298, 0,982], \quad [0,015, 0,701], \quad [0,00018, 0,0341].$$

8.3 Pourquoi nous l'appelons stable

Sur une boucle autonome, une variation qui avance simplement la phase n'est ni contractée ni amplifiée : son taux théorique est zéro. Le spectre mesuré sur 2000 unités est

$$(-0,00273, -0,45676, -0,45937). \quad (26)$$

Le premier nombre est l'approximation finie du zéro de phase. Les deux autres sont nettement négatifs : les écarts perpendiculaires à la boucle se contractent.

Nous avons également ajouté 128 perturbations gaussiennes d'écart-type 0,08 autour d'un point du cycle. La médiane de la distance à toute la boucle passe de 0,0525 à 0,00194 ; son quantile 90% passe de 0,0938 à 0,00320. Le plateau final est du même ordre que l'espacement utilisé pour stocker la boucle de référence.




Figure 2: Cycle interne de l'attention seule. À gauche, les deux angles relatifs décrivent une boucle fermée ; une rotation rigide serait un point. À droite, sept phases d'un tour montrent les trois jetons sur le cercle. Les angles sont toujours pris modulo 2π .

8.4 Le tour demande bien un nombre de couches proportionnel à $1/h$

Nous avons rejoué la couche exacte (4) pour sept ratios, dont trois non dyadiques. Le [table 3](#) donne le meilleur retour complet.

Table 3: Retour du cycle de l'attention seule lorsque chaque couche est affaiblie. Le temps d'un tour est le nombre de couches multiplié par le ratio.

Ratio	Couches par tour	Temps du tour	Erreur angulaire maximale
1/16	138	8,625	$2,38 \times 10^{-2}$
1/31	275	8,871	$9,46 \times 10^{-3}$
1/64	576	9,000	$5,38 \times 10^{-3}$
1/127	1151	9,063	$5,43 \times 10^{-5}$
1/256	2328	9,094	$1,13 \times 10^{-3}$
1/509	4635	9,106	$7,42 \times 10^{-4}$
1/1024	9333	9,114	$1,09 \times 10^{-5}$

La pente de $\log(\text{couches par tour})$ en fonction de $\log(1/\text{ratio})$ vaut 1,012. Le temps du tour tend vers celui de l'équation continue, tandis que le nombre de couches diverge.

8.5 Ce que les autres ablations ont donné

Le [table 4](#) empêche une conclusion trop large. Les trois candidats chaotiques les plus étudiés ne restent pas chaotiques lorsque le MLP est supprimé ; ils convergent à un équilibre dans l'ablation attention seule.

Limite de la conclusion. Nous avons certifié l'existence d'un cycle interne stable produit par l'attention seule. Nous n'avons pas encore effectué un recensement aléatoire exhaustif dédié uniquement à l'attention générale. Nous ne concluons donc ni que ce cycle est unique, ni qu'il est fréquent. Aucune des ablations ciblées ne fournit à ce jour un attracteur chaotique d'attention seule.




Figure 3: Un tour du cycle. En haut, les produits scalaires entre jetons oscillent ; en bas, les poids de la première ligne d’attention oscillent eux aussi. La deuxième période visible dans les distances provient d’une permutation de rôle entre jetons au cours du retour complet des angles étiquetés.

Table 4: Résultat des ablations attention seule sur les représentants étudiés en détail.

Origine du représentant	Structure de l’attention	Résultat sans MLP
Cycle à trois jetons, indice 1323	S général, V général, $\beta > 0$	cycle interne stable
Chaos fort à trois jetons, indice 2612	S symétrique, V général, $\beta > 0$	consensus fixe
Chaos faible à trois jetons, indice 1051	$S = V = V^T$, $\beta > 0$	consensus fixe
Intermittence à quatre jetons, indice 3118	S symétrique, V général, $\beta = 0$	équilibre fixe

9 Comparaison exacte avec Altafini et Kuehn–Yoon

9.1 Ce qu’Altafini suppose réellement

Le modèle d’Altafini contient bien les matrices Q et K . Son analyse principale suppose :

$$V = V^T, \quad \lambda_1 > 0 \text{ simple et strictement dominante.} \quad (27)$$

Elle ne suppose pas $Q^T K$ symétrique. Sous ces conditions, Altafini prouve que les équilibres à sortie nulle qu’il appelle polygonaux sont instables. Il montre aussi que des consensus bipolaires et des équilibres de regroupement peuvent être stables et coexister.

9.2 Pourquoi nos résultats ne contredisent pas ce théorème

Il y a trois raisons indépendantes :

1. le triangle stable de la [section 5](#) a des sorties non nulles. Il est dans la classe « clustering » d’Altafini, que son théorème n’annonce pas instable ;




Figure 4: À gauche, contraction de 128 perturbations vers la boucle. La ligne est la médiane et la zone contient 80% des essais. À droite, nombre de couches par tour ; la pente proche de un est la signature d’un cycle continu, et non d’un artefact à trois ou quatre couches.

2. les branches négatives définies de Kuehn–Yoon n’ont aucune valeur propre positive et sortent donc de (27) ;
3. le cycle de (25) utilise un V non symétrique et n’est pas un équilibre. Il sort à la fois de l’hypothèse sur V et de la question « stabilité d’un équilibre polygonal ».

9.3 Ce que l’hypothèse de Kuehn–Yoon ajoute

Kuehn–Yoon imposent la relation plus forte

$$Q^T K = V = V^T.$$

Elle fournit la quantité monotone (22). Leur article établit des résultats globaux de sélection dans un cône lorsque la valeur propre positive dominante dépasse en module les autres, et pour deux jetons lorsque V est négative définie [4]. Notre caractérisation (13) complète la question différente « quels sont tous les points d’arrêt possibles ? », y compris les branches mixtes et les multiplicités, sans prétendre que chacun est atteint depuis une initialisation générique.

Table 5: Portée des trois analyses.

	Altafini	Kuehn–Yoon	Présent rapport
MLP	absent	absent	absent
Score $S = Q^T K$	général	égal à V	général, puis cas égal à V
Valeur V	symétrique, sommet positif simple	symétrique, spectres ciblés	générale ; classification complète si liée symétrique
Équilibres	quatre classes, seuils sur branches pures	sélection spectrale et stabilité pure	condition nécessaire et suffisante, réduction par groupes, système spectral–Gram
Cycles	cycle possible signalé si V perd la symétrie	interdits par l’énergie	cycle interne stable explicite sans MLP

10 Ce qui est nouveau, dit simplement

1. **Une seule équation couvre toutes les destinations.** Les consensus, les deux groupes opposés, les triangles, les formes asymétriques et les familles continues sont tous les cas de (8). La somme n'a pas besoin de s'annuler ; elle doit seulement être radiale.
2. **Le mot polygone ne décide pas de la stabilité.** Un dessin à plusieurs sommets peut être stable lorsque les sorties sont non nulles. L'affirmation « polygonal instable » d'Altafini concerne uniquement les sorties exactement nulles.
3. **Sans MLP ne veut pas dire sans mouvement durable.** L'égalité $Q^T K = V = V^T$ force l'arrêt, mais une tête générale peut entretenir seule un cycle où les distances et les poids d'attention oscillent.
4. **Nous savons distinguer une boucle réelle d'un tour de passe-passe de discrétisation.** Dans notre cycle, affaiblir une couche multiplie le nombre de couches nécessaires par le facteur inverse, tout en gardant le temps d'un tour proche de 9,12.
5. **Le résultat est une existence, pas encore une statistique universelle.** Un cycle stable est certifié ; aucun chaos sans MLP ne l'est. La fréquence de ces cycles pour des matrices aléatoires reste une expérience fondamentale à faire.

11 Conclusion

Le système sans MLP est déjà assez riche pour avoir plusieurs destinations stables et, si la réciprocité est brisée, une oscillation interne stable. La frontière théorique est simple. Lorsque la même matrice symétrique calcule les scores et transporte les valeurs, une quantité augmente à chaque mouvement : les jetons doivent finir par s'arrêter. Quand les deux rôles sont séparés, cette barrière disparaît ; les sommes reçues peuvent se relancer mutuellement autour d'une boucle.

La condition finale à retenir est (8). Elle est exacte dans toute dimension. Elle dit ce qu'il faut résoudre pour énumérer les équilibres, ce qu'il faut différencier pour tester leur stabilité, et pourquoi une forme à plusieurs sommets peut être stable sans contredire Altafini. Le cycle explicite montre ensuite que les équilibres ne sont pas toute l'histoire dès que S et V ne sont plus liés par la symétrie forte de Kuehn–Yoon.

A Preuves complémentaires

A.1 Preuve du théorème spectral–Gram

Dans une base propre de V , écrivons $X = C_1 \oplus \dots \oplus C_s$. L'équation $RXV = MX$ projetée sur l'espace de valeur propre λ_α^* devient

$$(\lambda_\alpha^* R - M)C_\alpha = 0.$$

En multipliant à droite par C_α^T , on obtient $(\lambda_\alpha^* R - M)G_\alpha = 0$. Les identités sur H et les diagonales suivent de la décomposition orthogonale.

Réciproquement, factorisons toute solution positive $G_\alpha = C_\alpha C_\alpha^T$ avec au plus m_α colonnes. L'image de G_α est la même que celle de C_α ; l'équation sur G_α implique donc l'équation sur C_α . En plaçant ces facteurs dans des espaces propres orthogonaux, on reconstruit X et $RXV = MX$. Deux factorisations du même G_α diffèrent par une rotation interne à l'espace propre, ce qui prouve l'énoncé modulo ces rotations.

A.2 Preuve de la classification à $\beta = 0$

À attention uniforme, tous les champs ont la forme $P_{x_i}z/n$ avec $z = V \sum_j x_j$. Si $z = 0$, la configuration est arrêtée. Sinon, chaque x_i doit être parallèle à z , donc $x_i \in \{u, -u\}$ avec $u = z/\|z\|$. La somme vaut cu . Puis $z = cVu$ est parallèle à u , donc u est propre. Comme $z \neq 0$, c et la valeur propre associée sont non nuls. La réciproque est immédiate.

A.3 Absence de sorties nulles lorsque V est positive définie

Sous $S = V \succ 0$, regroupons les q positions distinctes w_a . La matrice

$$\mathcal{R}_{ab} = \exp\left(\beta \left\langle V^{1/2}w_a, V^{1/2}w_b \right\rangle\right)$$

est strictement positive définie pour des points distincts. Elle est donc inversible. La condition de sortie nulle s'écrit $\mathcal{R} \text{Diag}(r_1, \dots, r_q)WV = 0$. Puisque $\mathcal{R}$, $\text{Diag}(r_1, \dots, r_q)$ et V sont inversibles, cette égalité imposerait $W = 0$, ce qui contredit la norme un de ses lignes. Les équilibres à plusieurs sommets qui restent possibles ont donc nécessairement une sortie radiale non nulle.

B Jacobienne exacte sur le cercle

Cette annexe donne une formule directement programmable. Posons

$$g_{ij} = t_i^\top V x_j, \text{quad}s_{ij} = x_i^\top S x_j, \text{quad}f_i = \sum_j a_{ij} g_{ij}.$$

Pour l'angle θ_k ,

$$D_k s_{ij} = \mathbf{1}_{i=k} t_i^\top S x_j + \mathbf{1}_{j=k} x_i^\top S t_j, \quad (28)$$

$$D_k g_{ij} = -\mathbf{1}_{i=k} x_i^\top V x_j + \mathbf{1}_{j=k} t_i^\top V t_j. \quad (29)$$

La dérivée du softmax donne alors

$$J_{ik} = \sum_j a_{ij} \left[D_k g_{ij} + \beta g_{ij} \left(D_k s_{ij} - \sum_\ell a_{i\ell} D_k s_{i\ell} \right) \right]. \quad (30)$$

À un équilibre, les parties réelles des valeurs propres de J décident de la stabilité. Pour la couche finie, on calcule directement la Jacobienne de F_h ; ses valeurs propres doivent avoir un module inférieur à un. Pour h petit, un taux continu λ donne un multiplicateur de couche $1 + h\lambda + O(h^2)$.

C Partage bipolaire déséquilibré

Soit n_+ le nombre de $+u$, n_- le nombre de $-u$ et $r = n_+/n_-$. Pour une valeur propre λ_p , définissons

$$c = e^{2\beta\lambda_p}, \quad \sigma(c, r) = \frac{(c-r)(cr-1)}{r(c^2-1)}.$$

Si $\lambda_p > 0$, le partage est localement stable exactement lorsque

$$\lambda_p > \frac{|\log r|}{2\beta}, \quad \lambda_k < \lambda_p \sigma(c, r) \quad (k \neq p).$$

Si $\lambda_p < 0$, la condition est

$$\lambda_p < -\frac{|\log r|}{2\beta}, \quad \lambda_p < \lambda_k < \lambda_p \sigma(c, r) \quad (k \neq p).$$

Pour $r = 1$, $\sigma = \tanh(\beta\lambda_p)$ et l'on retrouve (20)–(21).

D Reproductibilité et traçabilité des affirmations

Les fichiers principaux sont :

- `experiments/spectral_self_attention/non_mlp_report_experiments.py` pour la réintégration, les perturbations, le test en profondeur et les figures ;
- `data/spectral_self_attention/non_mlp_report_results.json` pour tous les nombres affichés dans la section du cycle ;
- `data/spectral_self_attention/continuous_ode_f4_p3_cycle_attention_only.json` pour l'ablation initiale ;
- `data/spectral_self_attention/continuous_lyapunov_spectrum_f4_p3_cycle_attention_only_relaxed2.json` pour le spectre long ;
- `data/spectral_self_attention/equilibria/planar_small_systems.csv` et `search_saturation.csv` pour le catalogue de petits systèmes ;
- `experiments/spectral_self_attention/equilibrium_catalogue.py` et `run_equilibrium_catalogue.py` pour les racines d'équilibre.

Depuis la racine du dépôt, la commande

```
.venv/bin/python \
  experiments/spectral_self_attention/non_mlp_report_experiments.py
```

recrée les quatre figures et le résumé JSON. Les matrices de (25), les graines aléatoires, les pas, les durées et les seuils sont stockés dans ces fichiers.

Table 6: Statut exact des principales affirmations.

Affirmation	Statut
Condition (8)	théorème algébrique, nécessaire et suffisant
Système (13)	théorème, complet modulo rotations des espaces propres
Pas de cycle si $S = V = V^T$	conséquence exacte de (23)
Triangle stable affiché	racine numérique, résidu $< 1,3 \times 10^{-15}$, Jacobienne contractante
Cycle général sans MLP	certificat numérique : retour, spectre, perturbations et loi en profondeur
Absence de chaos sans MLP	non établie ; seulement constatée sur les ablations ciblées
Fréquence des cycles aléatoires	non mesurée dans un recensement dédié

Références

- [1] Claudio Altafini. Multistability of self-attention dynamics in transformers. *arXiv preprint arXiv:2511.11553*, 2025.
- [2] Borjan Geshkovski, Clément Letrouit, Yury Polyanskiy, and Philippe Rigollet. The emergence of clusters in self-attention dynamics. In *Advances in Neural Information Processing Systems*, volume 36, pages 57026–57037, 2023.
- [3] Borjan Geshkovski, Clément Letrouit, Yury Polyanskiy, and Philippe Rigollet. A mathematical perspective on transformers. *Bulletin of the American Mathematical Society*, 62(3):427–479, 2025.
- [4] Christian Kuehn and Jaeyoung Yoon. Spectral selection in symmetric self-attention dynamics. *arXiv preprint arXiv:2604.26085*, 2026.
- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [6] Biao Zhang and Rico Sennrich. Root mean square layer normalization. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

Dynamiques sphériques de Transformers

Volume II : MLP, cycles continus, chaos, multi-têtes et limite à beaucoup de tokens

Théorie et audit numérique reproductible, depuis une couche élémentaire

Soumission anonyme

Version du 16 août 2026

Résumé

Ce rapport part d'une couche Transformer réduite à quatre opérations : l'attention, une connexion résiduelle, une normalisation sur la sphère, puis un MLP quadratique suivi d'une seconde normalisation. Nous écrivons exactement tous ses points fixes et tous ses cycles, puis nous séparons les boucles qui n'existent qu'avec des couches fortes de celles qui survivent lorsque chaque couche devient infinitésimale. Un recensement initial de 28 672 modèles et 2 752 512 trajectoires trouve des cycles stables de trois et quatre couches dans les quatre familles structurelles. L'audit de la limite faible porte finalement sur 214 528 modèles tirés indépendamment et 2 844 160 trajectoires initiales. Parmi 1 908 attracteurs complexes rejoués dans l'équation continue, 1 699 s'arrêtent et 209 restent mobiles sur la fenêtre principale. Le type entièrement réciproque avec MLP potentiel s'arrête dans 286 cas sur 286 ; les trois autres types gardent des rotations, des cycles qui changent la forme des groupes, deux attracteurs chaotiques à trois tokens et un attracteur hyperchaotique à huit tokens. Les tests de pas, d'intégrateur, de perturbation, de divergence et de bassins sont indépendants.

Nous étudions ensuite ce que plusieurs têtes changent : elles ne superposent pas simplement leurs cartes de destinations, car leurs poussées s'additionnent avant que la destination soit choisie. En grande dimension, les tokens et les forces des têtes deviennent presque perpendiculaires, mais l'attention ne s'éteint pas : à température fixe, elle devient souvent plus uniforme. Quand le nombre de tokens tend vers l'infini, la somme devient une intégrale et les polygones deviennent des masses concentrées en plusieurs positions. Enfin, nous montrons comment un MLP entraîné peut maintenir un équilibre pendant presque toute la profondeur puis le quitter près de la sortie, comment une première étape de Muon diffère d'une étape de gradient, et comment des poids d'attention évoluant lentement selon un processus d'Ornstein–Uhlenbeck créent un régime de suivi retardé. Toutes les affirmations sont classées en résultats analytiques, observations numériques et pistes ouvertes.

Lecture concrète. L'attention choisit les partenaires et transporte leurs directions. Le MLP pousse chaque token en fonction de sa propre position. Si toutes ces poussées peuvent être résumées par une seule hauteur à gravir, les tokens finissent par s'arrêter. Si une partie de la poussée fait réellement tourner le système, on peut obtenir une horloge, une boucle stable ou un mouvement imprévisible. Le rapport mesure exactement où cette circulation apparaît et si elle survit à des couches arbitrairement faibles.

Table des matières

1 Réponse courte et statut des conclusions	3
2 Le bloc étudié, sans rien supposer au départ	3
3 Toutes les destinations et toutes les boucles	4
4 Quatre familles et inventaire à pas fini	5
5 Pourquoi les petits cycles ne suffisent pas	6
6 Les mouvements continus effectivement trouvés	8
7 Pourquoi une énergie existe parfois et parfois non	10
8 Plusieurs têtes : pas une superposition de dessins	10
9 Grande dimension : orthogonalité sans découplage	11
10 Quand les tokens deviennent une distribution	12
11 Changer l'exponentielle ou la normalisation	12
12 Le bon espace observable	13
13 Entraîner le MLP pour choisir la sortie	14
14 Poids variables avec la profondeur : premier audit OU lent	15
15 Lecture de physique statistique, précisément	16
16 Ce qui est nouveau par rapport à Altafini et au cas symétrique	16
17 Ce que la dynamique peut réellement résoudre	17
18 Limites, contrôles manquants et expériences prioritaires	17
19 Conclusion sans jargon	18
A Carte de reproductibilité	18
B Table de lecture des signatures locales	19

1 Réponse courte et statut des conclusions

Le volume I du dossier traite l'attention sans MLP. Il donne la condition exacte de tous les équilibres, la réduction spectrale lorsque $Q^\top K = V = V^\top$, les formes polygonales et un cycle stable produit par l'attention seule lorsque score et valeur sont déliés. Le présent volume ajoute le MLP, plusieurs têtes, beaucoup de tokens et des poids variables avec la profondeur.

Les conclusions qui résistent à tous nos contrôles sont les suivantes.

1. Un MLP placé *après* l'attention change fortement une couche finie. En revanche, quand chaque couche devient faible, le bloc en série et un bloc où les deux poussées seraient additionnées ont la même équation au premier ordre ; leur différence commence à l'ordre h^2 .
2. Les quatre familles testées possèdent beaucoup de points fixes et des cycles stables de trois ou quatre couches. Cela ne signifie pas que ces petits cycles survivent à la limite continue.
3. Dans la famille entièrement réciproque, tous les attracteurs complexes sélectionnés deviennent des points fixes quand on affaiblit les couches. Dès qu'un MLP général ou un transport de valeur non réciproque est autorisé, des mouvements continus peuvent survivre.
4. Plusieurs têtes choisissent une destination par leur somme. Elles peuvent créer une destination absente de chaque tête prise séparément, ou couper un bassin en plusieurs morceaux.
5. L'orthogonalité en grande dimension ne découple pas automatiquement les tokens. Avec les normalisations de notre audit, les scores deviennent proches et l'attention tend vers la moyenne globale.
6. Dans la limite de beaucoup de tokens, les mêmes équations deviennent une équation de transport pour une distribution. Les polygones ne disparaissent pas : leurs nombres de tokens par sommet deviennent des proportions de masse.
7. L'entraînement du MLP peut sélectionner quand quitter un attracteur. Notre expérience reproduit un long plateau suivi d'une action terminale, mais ne démontre pas qu'un Transformer résout arbitrairement un problème difficile.

Ce que cela ne prouve pas. Le recensement est massif mais fini. Il ne constitue pas une preuve couvrant toutes les matrices réelles. Nous n'affirmons ni qu'un problème NP-complet devient facile, ni qu'une analyse par répliques est déjà établie pour ce bloc exact, ni qu'un MLP quadratique permet d'imposer n'importe quelle configuration sans contrainte. Ces trois idées restent des programmes de recherche.

2 Le bloc étudié, sans rien supposer au départ

2.1 Les tokens et l'attention

Il y a n tokens. Chaque token est un vecteur $x_i \in \mathbb{R}^d$ de norme un. Les deux matrices effectivement visibles par une tête d'attention sont

$$S = Q^\top K, \quad V.$$

S décide qui regarde qui ; V décide ce qui est transporté. La dynamique gelée ne voit jamais Q et K séparément : deux factorisations donnant le même produit S produisent exactement les mêmes trajectoires.

Pour une netteté $\beta \geq 0$, posons

$$a_{ij}(X) = \frac{\exp(\beta x_i^\top S x_j)}{\sum_{k=1}^n \exp(\beta x_i^\top S x_k)}, \quad (1)$$

$$A_i(X) = \sum_{j=1}^n a_{ij}(X) V x_j. \quad (2)$$

Même lorsque $\beta = 0$, l'attention n'est pas retirée : chaque poids vaut $1/n$ et la matrice V transporte encore la moyenne des tokens.

2.2 Le MLP quadratique

Le plus petit MLP qui produit déjà plusieurs puits et de la circulation est

$$M(x) = b + Lx + \sum_{r=1}^m o_r (u_r^\top x + c_r)^2. \quad (3)$$

Sa largeur est m . Le vecteur u_r décide ce que le neurone caché mesure et o_r décide dans quelle direction sa réponse pousse.

Nous appelons ce MLP *potentiel* lorsque

$$L = L^\top, \quad o_r = \gamma_r u_r. \quad (4)$$

Dans ce cas il existe une fonction scalaire

$$\phi(x) = b^\top x + \frac{1}{2} x^\top L x + \sum_r \frac{\gamma_r}{3} (u_r^\top x + c_r)^3 \quad \text{telle que} \quad M = \nabla \phi. \quad (5)$$

Cette contrainte ne signifie pas que le MLP est faible : il peut créer plusieurs puits. Elle interdit seulement une poussée qui tourne sans être le versant d'une même surface.

2.3 La vraie couche en série

Notons $\mathcal{N}(z) = z / \|z\|$. Une couche de force $h > 0$ est

$$y_i = \mathcal{N}(x_i + h A_i(X)), \quad F_i(X) = \mathcal{N}(y_i + h M(y_i)). \quad (6)$$

Le MLP est donc bien *après* l'attention, comme dans le bloc sériel demandé. Le modèle de contrôle d'Isobe, Inoue et Imaizumi additionne au contraire un champ FFN au champ d'attention dans une équation continue [3]. Cette différence architecturale est importante à pas fini ; la prochaine section précise ce qu'elle devient lorsque h tend vers zéro.

3 Toutes les destinations et toutes les boucles

3.1 Équation exacte d'un point fixe

Proposition 3.1 (Condition nécessaire et suffisante pour une couche finie). *Une configuration X est un point fixe de la couche (6) si et seulement s'il existe, pour chaque token, un point intermédiaire unitaire y_i et deux nombres strictement positifs r_i, s_i tels que*

$$x_i + h A_i(X) = r_i y_i, \quad y_i + h M(y_i) = s_i x_i. \quad (7)$$

Démonstration. La première égalité dit exactement que la première normalisation produit y_i ; la seconde dit que la deuxième normalisation ramène vers x_i . La positivité de r_i et s_i conserve la direction au lieu de la renverser. Réciproquement, normaliser les deux égalités redonne (6) puis $F_i(X) = x_i$. $\square$

Cette écriture garde l'exponentielle du softmax dans A_i mais supprime les divisions de normalisation. Elle est donc directement utilisable par un solveur d'équations.

3.2 Équation exacte d'un cycle de longueur quelconque

Pour une période p , on introduit $X^0, \dots, X^{p-1}$ et $Y^0, \dots, Y^{p-1}$. On écrit (7) à chaque étape en remplaçant le dernier X par l'état suivant, puis on ferme la boucle :

$$x_i^k + hA_i(X^k) = r_i^k y_i^k, \quad (8)$$

$$y_i^k + hM(y_i^k) = s_i^k x_i^{k+1}, \quad (9)$$

$$X^p = X^0. \quad (10)$$

Pour demander une période primitive, on exclut les retours avant p . Ces équations couvrent donc tous les cycles, pas uniquement les triangles ou quadrilatères visibles.

3.3 Équation continue et condition finale

Pour un vecteur unitaire x et une poussée z ,

$$\mathcal{N}(x + hz) = x + h(I - xx^\top)z + O(h^2).$$

Appliquée deux fois à (6), cette identité donne

$$\dot{x}_i = (I - x_i x_i^\top) \{A_i(X) + M(x_i)\}. \quad (11)$$

Le caractère sériel apparaît seulement dans le terme d'ordre h^2 . Tous les équilibres continus sont donc exactement les solutions de

$$(I - x_i x_i^\top) \{A_i(X) + M(x_i)\} = 0, \quad i = 1, \dots, n. \quad (12)$$

Lecture concrète. À l'arrêt, la poussée totale peut être non nulle. Elle doit seulement être parallèle au token. La normalisation efface alors cette partie radiale. Avec le MLP, l'attention et le MLP peuvent aussi se neutraliser le long de la sphère : aucun des deux n'a besoin d'être séparément à l'équilibre.

3.4 Stabilité

La stabilité d'un point fixe se décide en perturbant tous les tokens dans les directions tangentes à leur sphère. Pour une couche finie, on calcule la matrice des dérivées de F restreinte à ces directions. Le point attire si toutes ses valeurs propres ont un module inférieur à un. Dans le flot continu, on dérive le membre droit de (11). Le point attire si toutes les parties réelles sont négatives. Ce test inclut les perturbations qui séparent deux tokens momentanément égaux ; il évite de confondre une égalité maintenue par l'arrondi numérique avec un vrai groupe stable.

4 Quatre familles et inventaire à pas fini

Les quatre familles croisent deux choix pour l'attention et deux choix pour le MLP.

Type	Attention	MLP
1	$S = V = V^\top$	potentiel
2	$S = V = V^\top$	quadratique général
3	S et V déliés	potentiel
4	S et V déliés	quadratique général

Pour les types 3 et 4, nous avons séparé quatre sous-cas : S et V symétriques, S symétrique et V générale, S générale et V symétrique, puis les deux générales. Les largeurs MLP sont 1, 2, 4 et 8 ; le nombre de tokens va de 1 à 4 dans l'inventaire principal.

Le premier balayage large contient 28 672 modèles, 96 départs par modèle et donc 2 752 512 trajectoires. Il teste cinq régimes de pas, de netteté et de rapport entre la force de l'attention et celle du MLP. Le type 3 est sur-échantillonné. Il s'agit d'un inventaire dense sur la grille choisie, pas d'une énumération de l'espace continu des matrices.

4.1 Beaucoup de destinations stables

La résolution directe des équations trouve, en moyenne, les nombres suivants de points fixes stables.

Type	1 token	2 tokens	3 tokens	maximum observé
1	1,68	2,34	3,09	8
2	1,49	2,03	2,55	9
3	1,57	2,13	2,61	8
4	1,31	1,71	2,00	7

Un contrôle construit avec trois puits donne exactement 3^n destinations stables étiquetées : 3, 9, 27, 81 et 243 pour un à cinq tokens. Cela montre comment une règle locale très simple peut créer un nombre combinatoire de répartitions finales.

4.2 Cycles de trois et quatre couches

Chaque candidat a été raffiné en résolvant $F^3(X) = X$ ou $F^4(X) = X$, puis son retour primitif et sa stabilité ont été testés sur tout le cycle.

Type	trajectoires p3	modèles p3	trajectoires p4	modèles p4
1	321	8	201	15
2	2 039	34	1 823	28
3	4 490	75	4 507	113
4	1 621	22	1 860	41

Des périodes primitives 5 à 12 sont également certifiées. Les quatre largeurs MLP en contiennent. Une attention uniforme ($\beta = 0$) en contient aussi. Le MLP général peut produire seul des p3 et p4 ; le MLP potentiel seul n'a produit aucun p3 certifié dans 65 536 trajectoires, et son unique candidat p4 s'est réduit à une période plus courte.

Résultat établi ici. La séparation décisive n'est pas simplement « potentiel ou non ». À pas fini, la composition de deux sous-étapes peut créer une boucle même si chacune possède une interprétation énergétique. À pas infinitésimal, ce qui compte est l'existence d'une circulation dans la somme des deux champs.

5 Pourquoi les petits cycles ne suffisent pas

Supposons $F_h = I + hf + O(h^2)$. Pour une période entière p fixée,

$$F_h^p(x) = x + phf(x) + O(h^2). \quad (13)$$




Figure 1: À gauche, cycles de quelques couches dans le premier balayage. À droite, part des attracteurs sélectionnés qui reste mobile après passage à l'équation continue. Les deux panneaux n'ont ni le même dénominateur ni la même question.

Un cycle qui garde exactement trois ou quatre couches pendant que h tend vers zéro ne peut donc s'accumuler que près d'un point où $f(x) = 0$. Un vrai cycle continu peut survivre, mais le nombre de couches nécessaires pour faire un tour doit croître comme T/h , où T est son temps physique de retour.

Sur toute durée physique fixée, la couche en série vérifie

$$\max_{0 \leq k \leq T/h} \|F_h^k(X) - \varphi_{kh}(X)\| = O(h), \quad (14)$$

où φ_t est le flot de (11). Cette convergence ne garantit pas que deux trajectoires chaotiques restent proches pour toujours. Elle garantit que l'équation continue est la bonne limite sur chaque fenêtre de temps fixée. Les distributions de trajectoires et les bassins sont donc vérifiés séparément.

5.1 Échelle finale de l'audit

L'audit complet rassemble :

- 214 528 modèles tirés indépendamment et 2 844 160 trajectoires initiales ;
- 26 112 contrôles frais, non sélectionnés, dans les 24 cases obtenues en croisant les quatre types avec 1, 2, 3, 4, 8 et 16 tokens ;
- 23 789 394 642 mises à jour modèle-couche, soit 102 108 101 290 mises à jour token-couche ;
- 307 200 000 évaluations RK4 de référence, soit 1 740 800 000 évaluations token-champ ;
- des pas allant jusqu'à $h/4096$, deux grilles non dyadiques, des temps physiques 2, 10 et 20, et des contrôles de Richardson qui annulent l'erreur du premier ordre.

La pente de l'erreur est 1 dans chaque famille. Après annulation de Richardson, elle est 2,018 sur la population principale. Au pas le plus fin, l'erreur médiane passe de $2,63 \times 10^{-4}$ à $3,39 \times 10^{-7}$. Ce test vérifie directement le développement $F_h = I + hf + h^2g + \dots$.

5.2 Recensement direct de la limite continue

Les 1 908 attracteurs sélectionnés sont rejoués directement avec (11).

Type	rejoués	fixes	mobiles	rotation rigide	forme interne mobile
1	286	286	0	0	0
2	378	313	65	38	27
3	768	732	36	21	15
4	476	368	108	55	53
Total	1 908	1 699	209	114	95

Ainsi, 89,0% des attracteurs complexes sélectionnés à pas fini deviennent des points fixes ; 11,0% restent mobiles sur la fenêtre principale. Ce taux est conditionnel à la sélection d'un attracteur complexe : ce n'est pas sa fréquence parmi toutes les matrices aléatoires.

Pour 8 et 16 tokens, 581 candidats sont poursuivis. Au pas $h/4096$, le comptage brut donne 118 mouvements. Quatre états apparemment fixes ont une direction instable masquée par des tokens numériquement égaux ; après correction, la carte finie et le flot continu donnent tous deux 122 mouvements et s'accordent individuellement dans 575 cas sur 581. Les six différences restantes choisissent des bassins coexistants.

6 Les mouvements continus effectivement trouvés

6.1 Cycles stables

Quatre cycles complets sont certifiés dans le bloc avec MLP : un p3 et un p4 issus du type 2, puis un p3 et un p4 issus du type 4. Leur temps de retour mesuré par la carte au pas le plus fin coïncide avec RK4 : respectivement 16,632 contre 16,660 ; 9,331 contre 9,340 ; 9,389 contre 9,400 ; 6,4395 contre 6,4400. Sur des grilles de pas qui ne sont pas des puissances de deux, les pentes du nombre de couches par tour sont 1,0016, 1,0029, 0,9992 et 0,9950. Chaque boucle attire toutes les perturbations de son audit de robustesse.

Le type 4 p3 est particulièrement instructif : l'attention seule garde le cycle, tandis que le MLP seul s'arrête. Ce cas appartient donc aussi au volume I. Dans les trois autres exemples, le MLP participe à la boucle.

6.2 Chaos à trois tokens

Un mouvement est appelé chaotique ici seulement après quatre contrôles : une direction de perturbation grandit en moyenne, une direction reste neutre parce qu'elle suit le temps le long de la trajectoire, les autres directions contractent, et la somme des taux coïncide avec la divergence moyenne calculée indépendamment.

Le cas type 4 à trois tokens a les taux

$$(0,1489, 0,0007, -0,3923).$$

Il reste positif dans 24 perturbations sur 24, pour trois pas RK4 ; au pas 0,005 son premier taux vaut 0,1584. Les 512 départs uniformes testés rejoignent tous un mouvement interne à taux positif. L'attention seule s'arrête ; le MLP seul donne une rotation régulière ; leur interaction donne le chaos.

Un second exemple de type 2 a les taux

$$(0,0333, -0,0011, -0,7253).$$

Ici l'attention seule et le MLP seul s'arrêtent tous les deux. Sur 512 départs, 449 dépassent le seuil strict 0,03 et les 63 autres restent positifs entre 0,022 et 0,03.




Figure 2: Taux complets des cycles et attracteurs chaotiques. Un point orange à droite de zéro signifie qu’une petite différence grandit ; un point bleu à gauche signifie qu’elle se rétracte ; un point gris près de zéro suit la phase du mouvement.

6.3 Hyperchaos et chimère à huit tokens

Un exemple de type 4 possède trois directions indépendantes de séparation :

$$(0,1458, 0,1455, 0,1435, 0,0031, -0,0409, -0,1871, -0,1872, -0,1896).$$

Une réplication avec un pas deux fois plus petit conserve trois taux positifs. Pendant ce mouvement, quatre tokens restent synchronisés ; la trajectoire alterne surtout entre des partitions $4 + 4$ et $4 + 3 + 1$. C’est une chimère : une partie du groupe reste ordonnée pendant que les phases des groupes évoluent de façon imprévisible. Les poids d’attention varient très peu, alors que la géométrie des tokens varie fortement.

6.4 Un cas intéressant même avec attention uniforme

À $\beta = 0$, chaque poids vaut toujours $1/n$. Pourtant un type 3 à quatre tokens garde un mouvement intermittent avec premier taux positif. Le mécanisme vient de la partie antisymétrique de V . La remplacer par sa partie symétrique, retirer l’attention ou retirer le MLP fait converger vers un point fixe. Dans un audit de 512 départs, le même jeu de poids possède à la fois des points fixes, des mouvements récurrents et des trajectoires à taux positif : l’initialisation choisit le bassin.

Sur le cercle, ce cas se réécrit exactement comme un groupe d’oscillateurs couplés. La partie antisymétrique de V fournit la tendance à tourner ; le MLP potentiel fournit des zones où le mouvement ralentit. L’attention uniforme n’est donc pas une absence d’interaction : elle est un couplage par la moyenne globale.

Ce que cela ne prouve pas. Aucun tore quasi périodique robuste n’a encore été certifié. Nous avons certifié des points fixes, des spirales stables, des cycles, du chaos et de l’hyperchaos, mais pas toutes les possibilités d’un système continu de grande dimension.

7 Pourquoi une énergie existe parfois et parfois non

Lorsque $\beta = 0$, $V = V^\top$ et le MLP est potentiel, la fonction

$$\Phi(X) = \frac{1}{2n} \sum_{i,j} x_i^\top V x_j + \sum_i \phi(x_i) \quad (15)$$

augmente le long de la trajectoire :

$$\frac{d\Phi}{dt} = \sum_i \left\| (I - x_i x_i^\top) \nabla_{x_i} \Phi \right\|^2 \geq 0.$$

Une boucle non constante reviendrait à la même valeur après un tour tout en ayant strictement augmenté ; elle est donc impossible. Les 146 contrôles continus exacts de ce cas finissent tous à l'équilibre.

La normalisation ligne par ligne du softmax peut briser cette structure simple même quand $S = V = V^\top$. Parmi 1 699 équilibres audités, 28 sont des spirales stables : une en type 1, dix-neuf en type 3 et huit en type 4 ; aucune n'apparaît dans le contrôle exact $\beta = 0$. La spirale isolée du type 1 montre que deux sous-champs symétriques ne garantissent pas, avec des mobilités différentes, une seule énergie euclidienne.

En multi-têtes non normalisées, des têtes symétriques et correctement alignées s'additionnent en une énergie commune. Avec des normalisations séparées, cette conclusion demande des conditions supplémentaires, car chaque tête multiplie sa poussée par son propre dénominateur. Les travaux de Pendharkar et de Massucco et collaborateurs donnent des conditions énergétiques dans des cadres multi-têtes précis [7, 6]. Notre audit montre ce qui se passe lorsque les sorties ne partagent plus cette énergie.

8 Plusieurs têtes : pas une superposition de dessins

Pour H têtes, la poussée est

$$A_i^{\text{multi}}(X) = \sum_{h=1}^H \omega_h \sum_j a_{ij}^{(h)}(X) C_h x_j. \quad (16)$$

La matrice de score de la tête h décide ses poids ; C_h inclut sa matrice de valeur et sa recombinaison de sortie. La destination satisfait

$$(I - x_i x_i^\top) \{A_i^{\text{multi}}(X) + M(x_i)\} = 0.$$

Il n'est pas nécessaire que chaque tête s'annule. Deux têtes peuvent se compenser le long de la sphère et créer une destination qui n'existe pour aucune tête seule.

8.1 Cartes conditionnelles de bassins

Nous fixons cinq tokens sur le cercle et laissons bouger une sixième sonde. Avec deux matrices ayant le même spectre $(2, -3)$ mais des axes tournés de 60 degrés, la tête A a 4 destinations, la tête B en a 5 et leur somme en a 7. Sur la sphère, les nombres sont 4, 4 et 5. La somme coupe les frontières, déplace les destinations et crée de petits bassins. Deux points initiaux très proches peuvent donc finir dans des groupes éloignés s'ils sont de part et d'autre d'une frontière.




Figure 3: À gauche, destination de la sonde selon son angle initial : A+B n'est pas la juxtaposition des deux premières lignes. À droite, en grande dimension, tokens et forces deviennent presque perpendiculaires tandis que le nombre de tokens effectivement écoutés monte vers 24.

8.2 Un cluster tournant créé par deux sorties

Une expérience à 64 tokens utilise deux têtes avec le même score $S = I$. La première sortie est $C_1 = I$ et rassemble les tokens. La seconde est $C_2 = 0,8J$, où J tourne un vecteur de 90 degrés. Le taux de synchronisation passe de 0,471 à 1,000, mais le cluster ne s'arrête jamais : sa vitesse angulaire mesurée vaut exactement 0,800000. La matrice de produits scalaires reste constante pendant cette rotation. Le noyau de score voit donc une configuration immobile alors que les valeurs transportées voient un cycle.

9 Grande dimension : orthogonalité sans découplage

Pour deux directions unitaires aléatoires en dimension d ,

$$\mathbb{E}|x^T y| \simeq \sqrt{\frac{2}{\pi d}}.$$

Avec 24 tokens, six têtes aléatoires et 96 répétitions par dimension, la proximité absolue entre tokens passe de 0,638 en dimension 2 à 0,050 en dimension 256. La proximité entre les forces des têtes passe de 1,000 à 0,049. Les têtes indépendantes se combinent donc presque comme des directions perpendiculaires.

Mais leurs scores deviennent aussi proches. Pour $\beta = 3$ fixé, le nombre effectif de tokens écoutés sur 24 passe de 11,6 à 23,6. La dynamique ne se décompose pas en 24 systèmes indépendants : elle conserve une moyenne globale presque uniforme.

Si $V = I$, le score propre reste 1 tandis que les scores croisés tendent vers zéro. Le poids propre limite vaut alors

$$a_{ii} \longrightarrow \frac{e^\beta}{e^\beta + n - 1}. \quad (17)$$

Il faut donc β sensiblement plus grand que $\log n$ pour un vrai auto-découplage. Pour une matrice aléatoire sans avantage diagonal, conserver des scores non triviaux dans notre normalisation demande typiquement β de l'ordre de $\sqrt{d}$.

Dans un Transformer pratique, la division par $\sqrt{d_{\text{head}}}$ et les normes apprises des requêtes et des clés sont précisément choisies pour garder des logits d'ordre un. L'orthogonalité brute des embeddings ne suffit donc pas à prédire le découplage d'un réseau entraîné.

10 Quand les tokens deviennent une distribution

Définissons la mesure empirique

$$\mu_t^n = \frac{1}{n} \sum_{i=1}^n \delta_{x_i(t)}.$$

Pour un noyau positif g et une attention normalisée, la vitesse au point x est

$$v_g[\mu](x) = P_x^\perp \frac{\int g(x^\top S y) V y d\mu(y)}{\int g(x^\top S y) d\mu(y)} + P_x^\perp M(x). \quad (18)$$

La limite de beaucoup de tokens est l'équation de transport

$$\partial_t \mu_t + \operatorname{div}_S(\mu_t v_g[\mu_t]) = 0. \quad (19)$$

Elle dit seulement que toute la masse de tokens est déplacée par un champ calculé à partir de la distribution entière. Les travaux de Rigollet et de Castin, Ablin, Carrillo et Peyré placent cette limite dans une géométrie de transport adaptée à la normalisation [9, 2].

Dans notre contrôle, une densité à trois bosses est échantillonnée puis comparée à une quadrature de 8 192 points. L'erreur sur la vitesse décroît comme $n^{-0,494}$, en accord avec la fluctuation $n^{-1/2}$: 0,289 à 16 tokens, 0,146 à 64, 0,071 à 256 et 0,038 à 1 024.

10.1 Les polygones deviennent des masses

Une distribution concentrée sur q positions s'écrit

$$\mu = \sum_{a=1}^q p_a \delta_{w_a}, \quad p_a > 0, \quad \sum_a p_a = 1.$$

Elle est stationnaire exactement lorsque

$$P_{w_a}^\perp \sum_b p_b g(w_a^\top S w_b) V w_b + P_{w_a}^\perp M(w_a) = 0 \quad \text{pour chaque } a. \quad (20)$$

Les nombres entiers de tokens placés à chaque sommet deviennent donc des masses réelles. Le passage à l'intégrale élargit la famille : les rapports de masses n'ont plus besoin d'être rationnels.

10.2 Que mesure Wasserstein ?

La distance de Wasserstein mesure le coût minimal pour déplacer un nuage de masse vers un autre. Elle convient naturellement à (19). Elle ne transforme pas automatiquement toute attention en descente d'énergie. Sans dénominateur et avec une interaction symétrique, une primitive G de g donne l'énergie

$$\mathcal{E}_G(\mu) = \frac{1}{2} \iint G(x^\top V y) d\mu(x) d\mu(y).$$

Le dénominateur du softmax change la mobilité locale. Des matrices déliées ou antisymétriques peuvent supprimer toute énergie commune.

11 Changer l'exponentielle ou la normalisation

Nous remplaçons $\exp(1,5s)$ par trois noyaux positifs dans le cas $V = \operatorname{diag}(2, -3)$ et trois masses égales.




Figure 4: À gauche, convergence de la somme de tokens vers l'intégrale. À droite, positions polygonales trouvées pour quatre noyaux ; le cercle vert indique une branche stable et la croix orange une branche instable.

Noyau	racines polygonales q	racine stable
exponentielle	-0,907, 0,024, 0,801	0,024
sigmoïde bornée	-0,680	aucune
softplus	-0,787	aucune
polynôme $(1 + s/3,01)^4$	-0,842, 0,231, 0,548	0,231

L'exponentielle n'est donc pas nécessaire à l'existence d'une forme polygonale, mais elle change ses branches et leur stabilité. Pour un noyau positif g , retirer seulement le dénominateur ne change pas les équilibres : il multiplie la vitesse par un facteur positif. Il peut cependant changer fortement les temps, les bassins et la métastabilité.

Retirer la sphère est une opération bien plus radicale. Un token placé sur la direction propre positive de valeur 2 garde sa norme avec la projection sphérique. Sans cette projection, sa norme atteint 10 au temps 1,151 avec attention normalisée ; sans sphère ni dénominateur, elle diverge au temps 0,003262 dans notre paramétrage exponentiel. Une poussée auparavant radiale et invisible change alors toute la dynamique.

12 Le bon espace observable

Les poids d'attention seuls ne décrivent pas l'état. Pour chaque tête, la vitesse dépend des deux fonctions

$$Z_h^\mu(x) = \int k_h(x, y) d\mu(y), \quad N_h^\mu(x) = \int k_h(x, y) C_h y d\mu(y). \quad (21)$$

La tête utilise N_h/Z_h . Il faut donc observer à la fois qui est choisi et ce qui est transporté. Avec un MLP quadratique, il faut aussi garder les mesures cachées $u_r^\top x_i + c_r$ et les projections linéaires utilisées en sortie.

Pour le cas symétrique aligné, la matrice $H = XVX^\top$ et ses morceaux par espace propre constituent une description fermée, à rotation près. Dans le cas général, une description minimale utile contient :

1. la géométrie des tokens, par exemple leur matrice de produits scalaires ;
2. les matrices de score et les poids de chaque tête ;
3. les directions après passage par les valeurs et les sorties ;




Figure 5: À gauche, contrôle entraîné : le polygone absorbe d’abord les perturbations, puis le MLP agit près de la sortie. À droite, une seule mise à jour à norme globale égale : le gradient et Muon optimisent des géométries différentes.

4. les features cachées du MLP ;
5. pour une tâche supervisée, les positions, labels et le readout.

L’exemple hyperchaotique rend ce point mesurable : l’écart-type temporel maximal des poids vaut seulement 0,0034, alors que celui de la géométrie de Gram vaut 0,481. Dans l’exemple à attention uniforme, la distance entre poids est exactement zéro à tous les pas, même lorsque la géométrie ne l’est pas.

13 Entraîner le MLP pour choisir la sortie

Isobe, Inoue et Imaizumi fixent une attention symétrique non normalisée, ajoutent du bruit et entraînent seulement un FFN linéaire en ses paramètres avec un coût quadratique [3]. Leur solution optimale a trois phases : les tokens se regroupent, restent longtemps près d’un puits, puis le FFN agit fortement près de la sortie pour réduire la perte terminale. Leur attention est en parallèle avec le FFN dans l’équation continue ; notre MLP est en série dans la couche finie. La section 2 montre pourquoi le mécanisme se compare au premier ordre, mais pas couche par couche à grand pas.

13.1 Contrôle entraîné autour d’un polygone

Nous entraînons un petit contrôle angulaire, linéaire en cinq features de Fourier, pour déplacer un polygone stable vers une cible tournée de 0,9 radian. Le contrôle maximal dans la première moitié vaut 0,0011 ; dans les cinq derniers intervalles, il atteint 2,19. L’erreur terminale vaut 0,00133. La force est donc environ 2 000 fois plus grande à la fin qu’au début. Le plateau d’Imaizumi survit lorsque le puits n’est plus un consensus mais un polygone.

Ce résultat donne un principe de conception : fixer une dynamique d’attention qui crée des bassins utiles, puis entraîner un MLP sériel pour rester dans un bassin, en sortir ou déplacer sa destination. Il ne garantit pas que toute condition algébrique soit encodable par un petit MLP, ni que l’entraînement trouve globalement les bons poids.

13.2 Une première étape de Muon

Si le gradient d’une matrice à la profondeur k est $G_k = U_k \Sigma_k V_k^\top$, une étape de gradient est $-\alpha G_k$. Une étape de Muon idéalisée utilise plutôt

$$-\eta U_k V_k^\top. \quad (22)$$

Elle garde les directions singulières et égalise les tailles non nulles. À la première étape, le momentum ne change que l’échelle globale du gradient, ensuite supprimée par ce facteur polaire. Sous une contrainte de norme opérateur par matrice, cette direction est la plus descendante ; sous la contrainte L^2 du théorème d’Imaizumi, le gradient est naturellement favorisé.

Dans notre analogue à 40 tranches, le gradient final est $7,11 \times 10^{11}$ fois plus grand que le gradient initial. À budget total 0,3, la perte passe de 0,37839 sans entraînement à 0,28547 avec le gradient, 0,35385 avec Muon exact et 0,35323 avec cinq itérations de Newton–Schulz. À budget 1,0, Muon agit bien plus tôt et détruit le plateau, tandis que le gradient concentre encore son action sur la dernière tranche. Ce n’est pas un classement universel : il montre que la norme choisie pour comparer les mises à jour décide du gagnant.

Des analyses récentes de mémoire associative expliquent autrement l’intérêt de Muon : il rend l’apprentissage des directions rares plus équilibré que des mises à jour anisotropes [11, 4]. Notre expérience ne remplace pas ces résultats ; elle montre leur analogue dans la profondeur d’une dynamique polygonale.

14 Poids variables avec la profondeur : premier audit OU lent

Massucco et collaborateurs représentent les têtes par une distribution de matrices qui change avec la profondeur [6]. Dans leur régime Ornstein–Uhlenbeck,

$$dD_t = (F - D_t)dt + \sqrt{2\sigma^2} dW_t, \quad (23)$$

la loi des poids revient exponentiellement vers une gaussienne centrée en F . Leur théorie et leurs expériences montrent alors la relaxation vers une configuration stationnaire ; avec des poids périodiques non amortis, la relaxation peut disparaître.

Notre première approche isole la vitesse de renouvellement. Elle utilise 32 tokens sur $\mathbb{S}^2$, quatre têtes, 12 répétitions, $\sigma = 0,65$, un pas 0,02 et 2 000 pas. La matrice moyenne cible a les valeurs propres (1,2, 1,0, 0,2). Le taux OU varie de 0 à 10.

À taux 0,01, la concentration tardive vaut 0,736 et le suivi de l’axe instantané 0,948. À taux 0,3, elles valent 0,850 et 0,855. À taux 3, la concentration est pratiquement 1, mais le suivi instantané n’est plus que 0,740 tandis que l’alignement avec l’axe moyen vaut 0,897. La vitesse tardive croît de 0,040 à 0,352. Cela met en évidence trois temps : la contraction des tokens, le mouvement du paysage et le moyennage du bruit.

Lecture concrète. Lent ne signifie pas nécessairement plus chaotique. Si les tokens se contractent bien plus vite que les poids ne bougent, ils suivent quasi statiquement une branche. La complexité apparaît près des changements de bassin et lorsque les deux temps deviennent comparables : retard, sauts, mémoire du chemin et coexistence. Le présent balayage mesure le retard et la concentration ; il ne certifie pas encore un attracteur chaotique causé par l’OU lent.




Figure 6: Premier balayage du temps de corrélation des poids. À faible taux, le paysage reste longtemps déformé et le nuage ne se concentre pas complètement. À taux intermédiaire, les tokens tentent de suivre un axe mouvant avec retard. À taux élevé, le bruit se moyenne vite, le nuage se concentre près de l'axe moyen mais garde une vitesse instantanée élevée.

15 Lecture de physique statistique, précisément

Chaque ligne de softmax est exactement une loi de Boltzmann conditionnelle :

$$a_{ij} = \frac{e^{-E_{ij}/T}}{\sum_k e^{-E_{ik}/T}}, \quad E_{ij} = -x_i^\top S x_j, \quad T = 1/\beta.$$

Cela ne fait pas encore du système une matière à l'équilibre : les poids sont des probabilités de Boltzmann, mais la trajectoire des tokens est déterministe. Un vrai bain thermique demanderait un bruit brownien tangent. Si le champ est un gradient et le bruit accordé à sa mobilité, la loi stationnaire est de Gibbs. Avec transport antisymétrique ou MLP général, des courants peuvent persister et le système reste hors équilibre.

Les modèles voisins sont les mémoires de Hopfield modernes, les spins XY ou Heisenberg, les oscillateurs de Kuramoto ou Lohe et les verres de spins [8, 10]. Notre cas exact se distingue par trois traits : le couplage dépend de l'état, il est normalisé séparément pour chaque token, et les valeurs transportées peuvent ne pas être réciproques.

Une analyse de répliques demanderait de choisir un ensemble aléatoire précis de matrices, une limite conjointe du nombre de tokens, de la dimension et du nombre de têtes, puis un observable de recouvrement. La matrice des produits scalaires entre deux copies soumises aux mêmes poids est un candidat naturel, mais les poids d'attention ne suffisent pas : les valeurs et les features du MLP doivent aussi entrer. Les travaux de physique statistique des chemins d'attention sont voisins, sans fournir à ce jour la solution par répliques de notre bloc sériel exact [10].

16 Ce qui est nouveau par rapport à Altafini et au cas symétrique

Altafini étudie une dynamique d'attention et sa multistabilité sans MLP sériel ; son écriture travaille avec les matrices effectives de l'interaction plutôt qu'avec une factorisation architecturale séparée Q/K [1]. Son résultat d'instabilité des équilibres polygonaux concerne sa classe précise, notamment les configurations où la somme reçue s'annule. Il ne dit pas que toute forme à plusieurs sommets, après ajout d'un MLP ou déliaison score-valeur, doit être instable.

Kuehn et Yoon imposent $Q^T K = V = V^T$ et obtiennent une sélection par les espaces propres ainsi qu’une structure de flot de gradient [5]. Le volume I étend l’équation des équilibres à $S \neq V$ et certifie un cycle interne stable produit par l’attention seule. Le présent volume ajoute :

1. la condition exacte de tous les points fixes et cycles du bloc sériel attention–MLP ;
2. une taxonomie expérimentale des quatre croisements réciproque/délié et potentiel/général ;
3. la preuve que les p3/p4 fixes ne peuvent rester des p3/p4 quand $h \rightarrow 0$, puis leur audit jusqu’à $h/4096$;
4. des cycles continus stables, deux chaos à trois tokens et un hyperchaos à huit tokens dans le bloc complet ;
5. la démonstration que des poids d’attention constants peuvent cacher un mouvement interne ;
6. des cartes multi-têtes où la somme crée de nouvelles destinations ;
7. la distinction expérimentale entre orthogonalité, uniformisation et vrai découplage en grande dimension ;
8. le passage des polygones finis aux mesures atomiques, le changement de noyau, le contrôle entraîné, une étape de Muon et le premier balayage OU lent.

Résultat établi ici. L’ajout central n’est pas « davantage de formes ». C’est une règle permettant de distinguer les formes qui sont de vraies destinations, les boucles artificielles d’une couche trop forte, et les mouvements qui restent vivants dans une profondeur continue. Cette règle repose sur l’équation tangentielle finale, l’échelle $1/h$ du temps de retour et le spectre complet des perturbations.

17 Ce que la dynamique peut réellement résoudre

Les solutions exactes produites par la dynamique sont les vecteurs unitaires qui satisfont (12), ou les suites périodiques qui satisfont (10). En choisissant S, V et M , on choisit donc une famille d’équations non linéaires sur un produit de sphères. Les cas potentiels correspondent à des conditions de stationnarité avec contraintes de norme ; les cas non potentiels ajoutent une circulation et ne sont plus la minimisation d’une seule fonction.

Cela permet d’encoder des tâches utiles : mémoire associative, regroupement, choix parmi plusieurs codes sphériques, maintien d’une horloge, suivi d’un paysage variable, ou contrôle d’un état vers une cible. Cela ne rend pas automatiquement facile le problème inverse « trouver les poids qui réalisent la bonne famille de solutions ». L’entraînement peut lui-même rester non convexe, posséder de mauvais bassins et exiger un nombre exponentiel d’essais.

MaxCut fournit un bon contre-exemple à une conclusion trop forte. On peut encoder des signes unitaires et une énergie de coupe, puis laisser une dynamique chercher un point stationnaire. Elle peut donner une excellente coupe et le bruit OU peut aider à changer de bassin. Cela ne prouve ni l’optimalité globale ni un algorithme polynomial pour tous les graphes. Le bon énoncé est : cette dynamique forme une nouvelle famille d’heuristiques continues et entraînaibles pour des équations contraintes ; leur complexité doit être étudiée problème par problème.

18 Limites, contrôles manquants et expériences prioritaires

Les contrôles les plus importants qui restent sont :

1. reproduire les cycles et le chaos avec de vraies dimensions de tête, des matrices W^O explicites et RMSNorm plutôt qu’une sphère idéale ;
2. entraîner le bloc sériel complet, et pas seulement un contrôle FFN réduit, sur une tâche avec validation hors échantillon ;

3. faire varier conjointement nombre de tokens, dimension, température et nombre de têtes afin de distinguer limite moyenne, limite de tête et limite de dimension ;
4. cartographier les bifurcations lorsque les poids OU évoluent aussi lentement que le temps de relaxation des tokens, avec mesures d'hystérésis et de sauts de bassin ;
5. tester si les attracteurs chaotiques certifiés persistent après ajout de bruit, de biais, de LayerNorm affine et de précision réduite ;
6. construire une expérience de répliques avec deux copies et mêmes poids, puis mesurer le recouvrement complet incluant valeurs et MLP ;
7. donner une borne d'approximation reliant la largeur et le degré du MLP aux champs tangentiels réalisables sur la sphère ;
8. séparer performance d'optimisation et coût total pour Muon, gradient et Adam sur le même contrôle de profondeur.

19 Conclusion sans jargon

Un token reçoit deux sortes de coups. L'attention lui dit vers quels autres tokens se tourner. Le MLP lui donne une poussée qui dépend de sa propre position. Après chaque coup, la normalisation le remet sur la sphère.

Pour savoir où tout peut finir, il suffit de vérifier une règle : après addition de toutes les poussées, il ne doit rester aucun morceau qui fasse glisser le token le long de la sphère. Cette règle donne toutes les destinations, même lorsqu'elles ont plusieurs groupes et même lorsque l'attention et le MLP se compensent.

Les boucles demandent plus de prudence. Une boucle de trois couches peut seulement venir de coups trop forts. Quand on divise la force d'une couche par mille, une vraie boucle ne fait plus un tour en trois couches : elle utilise environ mille fois plus de couches et garde le même temps total. C'est exactement ce que font nos cycles continus. Dans la famille la plus symétrique, toutes les boucles sélectionnées finissent par s'arrêter. Dans les autres familles, certaines continuent ; quelques-unes deviennent même imprévisibles tout en restant confinées.

Plusieurs têtes ne votent pas séparément pour un sommet. Elles additionnent leurs poussées, et cette somme redessine les frontières. En grande dimension, elles deviennent presque perpendiculaires, mais elles peuvent encore écouter presque tout le monde. Avec beaucoup de tokens, on remplace simplement le nuage par une distribution : les groupes deviennent des parts de masse.

Enfin, l'entraînement ne sert pas seulement à choisir une destination. Il peut choisir quand rester dans un groupe et quand le quitter. Muon et le gradient répartissent ce premier changement de poids de façons très différentes. Des poids OU ajoutent encore une horloge externe : s'ils bougent lentement, les tokens les suivent avec retard ; s'ils bougent vite, le bruit se moyenne et les tokens voient surtout le paysage moyen.

Le résultat nouveau est donc une carte opérationnelle : quelles équations définissent les fins possibles, quelles structures forcent l'arrêt, quelles structures permettent une circulation, et quels tests séparent une vraie dynamique profonde d'un simple effet de couche forte.

A Carte de reproductibilité

Les expériences principales sont disponibles dans les fichiers suivants :

- inventaire à pas fini : `experiments/spectral_self_attention/large_scale_cycle_census.py` ;
- résolution des points fixes : `experiments/spectral_self_attention/equilibrium_root_census.py` ;

- certification des cycles : `experiments/spectral_self_attention/periodic_orbit_audit.py` ;
- poursuite vers $h/4096$: `experiments/spectral_self_attention/small_step_continuation.py` et `extend_small_step_continuation.py` ;
- intégration continue, robustesse et spectres : `continuous_ode_audit.py`, `continuous_ode_robustness.py` et `continuous_lyapunov_spectrum.py` ;
- limites à beaucoup de tokens et noyaux : `mean_field_extensions.py` ;
- multi-têtes et grande dimension : `multihead_phase.py` ;
- première étape de Muon : `one_step_muon.py` ;
- poids OU lents : `slow_ou_tokens.py` ;
- figures du présent rapport : `global_report_figures.py`.

Les agrégats numériques utilisés dans le texte sont `data/spectral_self_attention/large_taxonomy_summary.json`, `small_step_final_results.json`, `mean_field_extensions/summary.json`, `one_step_muon/summary.json`, `multihead/frozen_probe_basins.json` et `slow_ou_tokens.json`.

B Table de lecture des signatures locales

Objet	Ce que font les petites différences	Signature continue
Point fixe stable	elles diminuent toutes	toutes les parties réelles sont négatives
Selle ou répulseur	au moins une grandit	au moins une partie réelle est positive
Spirale stable	elles tournent en diminuant	paire complexe à partie réelle négative
Cycle stable	une suit la phase, les autres diminuent	un zéro, le reste négatif
Tore à k phases	k décalages persistent	k zéros, le reste non positif
Chaos	une grandit, une suit le temps, d'autres diminuent	positif, zéro, puis contraction
Hyperchaos	plusieurs différences grandissent indépendamment	au moins deux taux positifs

Une matrice non normale peut amplifier une perturbation pendant un temps limité même si tous ses taux asymptotiques sont négatifs. C'est pourquoi l'audit combine spectre local, trajectoires longues et perturbations répétées.

Références

- [1] Claudio Altafini. Multistability of self-attention dynamics in transformers. *arXiv preprint arXiv:2511.11553*, 2025.
- [2] Valentin Castin, Pierre Ablin, José A. Carrillo, and Gabriel Peyré. A unified perspective on the dynamics of deep transformers. *arXiv preprint arXiv:2501.18322*, 2025.
- [3] Noboru Isobe, Daisuke Inoue, and Masaaki Imaizumi. Training-induced escape from token clustering in a mean-field formulation of transformers. *arXiv preprint arXiv:2605.07772*, 2026.

- [4] Juno Kim, Eshaan Nichani, Denny Wu, Alberto Bietti, and Jason D. Lee. Sharp capacity scaling of spectral optimizers in learning associative memory. *arXiv preprint arXiv:2603.26554*, 2026.
- [5] Christian Kuehn and Jaeyoung Yoon. Spectral selection in symmetric self-attention dynamics. *arXiv preprint arXiv:2604.26085*, 2026.
- [6] Alex Massucco, Leonardo Del Grande, Marcello Carioni, Christoph Brune, and Carola-Bibiane Schönlieb. Multi-headed transformer architectures as time-dependent wasserstein gradient flows. *arXiv preprint arXiv:2605.18870*, 2026.
- [7] Ayan Pendharkar. Gradient flow structure and quantitative dynamics of multi-head self-attention. *arXiv preprint arXiv:2605.04279*, 2026.
- [8] Hubert Ramsauer, Bernhard Schäfl, Johannes Lehner, Philipp Seidl, Michael Widrich, Thomas Adler, Lukas Gruber, Markus Holzleitner, Milena Pavlović, Geir Kjetil Sandve, Victor Greiff, David Kreil, Michael Kopp, Günter Klambauer, Johannes Brandstetter, and Sepp Hochreiter. Hopfield networks is all you need. In *International Conference on Learning Representations*, 2021.
- [9] Philippe Rigollet. The mean-field dynamics of transformers. *arXiv preprint arXiv:2512.01868*, 2025.
- [10] Luca Tiberi et al. Dissecting the interplay of attention paths in a statistical mechanics theory of transformers. *arXiv preprint arXiv:2405.15926*, 2024.
- [11] Shuche Wang, Fengzhuo Zhang, Jiaxiang Li, Cunxiao Du, Chao Du, Tianyu Pang, Zhuoran Yang, Mingyi Hong, and Vincent Y. F. Tan. Muon outperforms adam in tail-end associative memory learning. *arXiv preprint arXiv:2509.26030*, 2025.