

Attention sphérique sans MLP : équilibres exacts, multistabilité et cycle interne stable

Rapport théorique et numérique reproductible

Soumission anonyme

Version du 16 août 2026

Résumé

Nous étudions une pile de couches réduite à son mécanisme d'attention : aucun réseau MLP n'est présent. Chaque jeton est un point de norme un et chaque couche le déplace, puis le renormalise. Le premier résultat est une condition nécessaire et suffisante, valable pour tout nombre de jetons, toute dimension et toutes matrices de score et de valeur : à l'équilibre, la moyenne transportée vue par chaque jeton doit être exactement parallèle à ce jeton. Nous donnons sa version pour une couche finie, sa réduction par groupes, sa linéarisation exacte et, dans le cas lié $Q^T K = V = V^T$, une description complète par matrices de produits scalaires. Cette description contient les consensus, les séparations en deux signes, les formes à plusieurs sommets, les familles continues et les mélanges de directions propres.

Le second résultat sépare trois objets souvent confondus : un cycle de trois ou quatre couches, un cycle continu dont le nombre de couches par tour croît comme l'inverse de la force d'une couche, et une simple rotation rigide. Dans le cas lié symétrique, une quantité scalaire augmente strictement et interdit tout cycle continu non constant. En revanche, lorsque les matrices de score et de valeur sont indépendantes et que le transport par V n'est pas réciproque, l'attention seule produit un cycle interne stable à trois jetons. Son temps de retour est 9,12 dans l'unité de profondeur de l'audit ; ses deux taux de contraction transverses sont proches de $-0,457$ et $-0,459$; 128 perturbations reviennent vers la même boucle. Pour sept forces de couche, dyadiques et non dyadiques, le nombre de couches par tour suit une pente 1,012 en échelle logarithmique. Nous n'avons, à ce stade, certifié ni chaos produit par l'attention seule ni inventaire exhaustif des cycles dans le cas non réciproque.

Lecture concrète. Le message en une phrase est le suivant : sans MLP, l'attention symétrique peut avoir beaucoup de destinations stables mais elle finit par s'arrêter ; l'attention générale peut, à elle seule, maintenir une boucle stable où les distances entre jetons changent indéfiniment.

Table des matières

1	Question étudiée et réponse courte	3
2	Le modèle, depuis une couche jusqu'au temps continu	3
3	La condition finale de tous les équilibres	4
4	Cas lié symétrique : une description complète	5
5	Quand un équilibre attire-t-il les trajectoires ?	7
6	Cycles : trois objets qu'il faut séparer	8
7	Pourquoi la symétrie interdit les cycles continus	9
8	Expérience centrale : un cycle stable produit par l'attention seule	10
9	Comparaison exacte avec Altafini et Kuehn–Yoon	12
10	Ce qui est nouveau, dit simplement	14
11	Conclusion	14
A	Preuves complémentaires	14
B	Jacobienne exacte sur le cercle	15
C	Partage bipolaire déséquilibré	15
D	Reproductibilité et traçabilité des affirmations	16

1 Question étudiée et réponse courte

Une couche Transformer usuelle contient au moins une attention, une connexion résiduelle, une normalisation et un MLP [5]. Nous retirons ici complètement le MLP. Il reste une question très précise : que peuvent faire les jetons lorsqu'on répète uniquement l'attention et la normalisation ?

Les travaux de Geshkovski et collaborateurs ont montré que cette lecture en profondeur comme une dynamique de particules explique la formation de groupes [2, 3]. Altafini a classé quatre formes d'équilibre et mis en évidence leur coexistence [1]. Kuehn et Yoon ont ensuite isolé un cas plus contraint, $Q^\top K = V = V^\top$, dans lequel les directions propres de V organisent la destination [4]. Notre rapport réunit ces points de vue, ferme l'équation générale des équilibres et ajoute l'étude expérimentale des cycles sans MLP.

Les réponses sont :

1. une configuration est arrêtée si et seulement si chaque jeton reçoit une somme qui pointe exactement dans sa direction ou dans la direction opposée ; la normalisation enlève alors la partie radiale et aucun angle ne change ;
2. une forme visuellement polygonale n'est pas nécessairement un « équilibre polygonal » au sens d'Altafini : ce nom y désigne seulement le cas plus étroit où la somme reçue est nulle ;
3. si score et valeur sont la même matrice symétrique, aucun cycle continu stable ne peut exister ;
4. si l'on défait cette égalité, l'attention seule peut soutenir un cycle interne stable ; nous en donnons un exemple explicite et reproductible ;
5. un cycle de période trois couches observé à grande force n'est pas la même chose qu'un cycle continu. Le second demande de plus en plus de couches lorsque chaque couche devient plus faible.

2 Le modèle, depuis une couche jusqu'au temps continu

2.1 Ce que représentent les symboles

Il y a n jetons. Le jeton i est un vecteur $x_i \in \mathbb{R}^d$ de norme un. Il vit donc sur la sphère $\mathbb{S}^{d-1}$. Deux matrices suffisent :

- $S = Q^\top K$ décide qui regarde qui ;
- V décide quel vecteur est effectivement transporté.

Le nombre $\beta \geq 0$ règle la netteté du choix. Pour $\beta = 0$, tous les jetons sont pondérés de la même façon. Lorsque β augmente, les différences de scores comptent davantage. Pour une configuration $X = (x_1, \dots, x_n)$, posons

$$s_{ij}(X) = x_i^\top S x_j, \quad (1)$$

$$a_{ij}(X) = \frac{\exp(\beta s_{ij}(X))}{\sum_{k=1}^n \exp(\beta s_{ik}(X))}, \quad (2)$$

$$y_i(X) = \sum_{j=1}^n a_{ij}(X) V x_j. \quad (3)$$

a_{ij} est le poids donné par i à j , et y_i est la somme reçue par i après le transport par V .

2.2 Une couche finie

Sans MLP, la couche résiduelle normalisée est exactement

$$x_i^+ = \frac{x_i + hy_i(X)}{\|x_i + hy_i(X)\|}, \quad i = 1, \dots, n, \quad (4)$$

où $h > 0$ est la force d'une couche. Cette normalisation sur la sphère est une version idéalisée de RMSNorm [6].

2.3 Beaucoup de couches faibles

Écrivons

$$P_x = I - xx^\top.$$

$P_x z$ garde seulement la partie de z qui change la direction de x ; la partie parallèle à x changerait seulement sa longueur et sera supprimée par la normalisation. Le développement de (4) donne

$$x_i^+ = x_i + hP_{x_i}y_i(X) + O(h^2).$$

Si le nombre de couches croît pendant que h décroît, la limite est

$$\boxed{x_i = P_{x_i}y_i(X) = y_i(X) - (x_i^\top y_i(X))x_i.} \quad (5)$$

La norme reste égale à un car $x_i^\top \dot{x}_i = 0$.

Sur le cercle, on écrit $x_i = (\cos \theta_i, \sin \theta_i)$ et $t_i = (-\sin \theta_i, \cos \theta_i)$. L'équation devient un seul nombre par jeton :

$$\dot{\theta}_i = \sum_{j=1}^n a_{ij}(\theta) t_i^\top V x_j. \quad (6)$$

Toutes les expériences de cycle de ce rapport utilisent cette équation à trois jetons.

3 La condition finale de tous les équilibres

Théorème 3.1 (Condition nécessaire et suffisante, matrices générales). *Une configuration $X \in (\mathbb{S}^{d-1})^n$ est un équilibre de (5) si et seulement si, pour chaque jeton i ,*

$$\boxed{y_i(X) = \lambda_i x_i, \quad \lambda_i = x_i^\top y_i(X).} \quad (7)$$

De façon équivalente, sans dénominateur softmax,

$$\boxed{\sum_{j=1}^n e^{\beta x_i^\top S x_j} [V x_j - (x_i^\top V x_j) x_i] = 0, \quad i = 1, \dots, n.} \quad (8)$$

Démonstration. Le champ est $P_{x_i}y_i$. Il est nul exactement lorsque y_i appartient à la droite portée par x_i . Le coefficient de cette colinéarité est son produit scalaire avec x_i . Enfin, le dénominateur du softmax est strictement positif ; le multiplier ou le supprimer ne change donc pas l'égalité à zéro. $\square$

Lecture concrète. Il n'est pas nécessaire que la somme reçue soit nulle. Elle peut être grande. Il suffit qu'elle pousse exactement vers le centre ou vers l'extérieur le long du rayon du jeton. La renormalisation efface cette poussée radiale. C'est la raison simple pour laquelle des formes à plusieurs sommets peuvent être stables.

3.1 La condition exacte pour une couche finie

Proposition 3.2 (Point fixe de la couche). *Supposons $x_i + hy_i \neq 0$. La couche (4) laisse x_i inchangé si et seulement si*

$$P_{x_i} y_i = 0 \quad \text{et} \quad 1 + h\lambda_i > 0, \quad \lambda_i = x_i^\top y_i. \quad (9)$$

La première condition est la même que pour le temps continu. La seconde est propre à une couche finie : si $1 + h\lambda_i < 0$, la normalisation retourne le point antipodal $-x_i$; si $1 + h\lambda_i = 0$, elle tente de normaliser le vecteur nul.

3.2 Réduction exacte lorsque plusieurs jetons coïncident

Supposons que la configuration contienne seulement q positions distinctes $w_1, \dots, w_q$, répétées respectivement $r_1, \dots, r_q$ fois. Alors (8) devient le système fini

$$\sum_{b=1}^q r_b e^{\beta w_a^\top S w_b} [V w_b - (w_a^\top V w_b) w_a] = 0, \quad a = 1, \dots, q. \quad (10)$$

Ce n'est pas une approximation. On a seulement regroupé des termes identiques. Pour une instance fixée, (10) donne une procédure exhaustive : énumérer les partitions $r_1 + \dots + r_q = n$, résoudre les équations, puis retirer les copies obtenues par permutation.

3.3 Pourquoi le mot « polygone » a créé une confusion

Altafini [1] emploie quatre noms. La distinction utile est résumée dans le [table 1](#).

Table 1: Les quatre noms d'Altafini, exprimés avec la somme y_i de (3). Les deux dernières lignes couvrent toutes les formes non colinéaires.

Nom	Configuration	Condition reçue
Consensus	tous les x_i sont égaux à une direction propre de V	$y_i \parallel x_i$
Consensus bipolaire	chaque x_i vaut u ou $-u$, avec u propre	$y_i \parallel x_i$
Polygonal	plusieurs directions, et aucune sortie	$y_i = 0$ pour tout i
Clustering	tout autre équilibre, avec ou sans jetons coïncidents	$y_i = \lambda_i x_i$, au moins un $\lambda_i \neq 0$

Ainsi, « les points dessinent un triangle » est une description visuelle. « Polygonal » au sens du théorème d'Altafini est une condition algébrique beaucoup plus étroite. Un triangle dont les trois sorties sont non nulles et radiales appartient à sa quatrième classe. L'instabilité des sorties nulles ne dit rien contre la stabilité de ce triangle.

4 Cas lié symétrique : une description complète

Nous imposons maintenant

$$S = V = V^\top. \quad (11)$$

C'est exactement l'hypothèse de Kuehn–Yoon [4]. Elle est plus forte que celle d'Altafini : Altafini suppose V symétrique avec une valeur propre positive dominante simple, mais ne demande pas que $Q^\top K$ soit symétrique ni égal à V .

Écrivons les jetons comme les lignes d'une matrice $X \in \mathbb{R}^{n \times d}$ et posons

$$H = XVX^\top, \quad R = \exp_o(\beta H),$$

où l'exponentielle est appliquée entrée par entrée. Définissons

$$M = \text{Diag}(\text{diag}(RH)).$$

Théorème 4.1 (Équation vectorielle complète). *Sous (11),*

$$X \text{ est un équilibre} \iff RXV = MX, \text{quad} \text{diag}(XX^\top) = \mathbf{1}. \quad (12)$$

Cette formule est déjà nécessaire et suffisante. La suivante retire les rotations qui ne changent pas le problème.

Théorème 4.2 (Description spectrale par produits scalaires). *Soient $\lambda_1^*, \dots, \lambda_s^*$ les valeurs propres distinctes de V , de multiplicités $m_1, \dots, m_s$. Écrivons la partie de X dans chaque espace propre sous la forme $C_\alpha \in \mathbb{R}^{n \times m_\alpha}$ et posons $G_\alpha = C_\alpha C_\alpha^\top$. Modulo les rotations internes aux espaces propres, les équilibres sont exactement les familles (G_α) satisfaisant*

$$\begin{aligned} &G_\alpha \succeq 0, \text{quad} \text{rang } G_\alpha \leq m_\alpha, \\ &\sum_{\alpha=1}^s \text{diag } G_\alpha = \mathbf{1}, \\ &H = \sum_{\alpha=1}^s \lambda_\alpha^* G_\alpha, \quad R = \exp_o(\beta H), \\ &M = \text{Diag}(\text{diag}(RH)), \\ &(\lambda_\alpha^* R - M)G_\alpha = 0, \quad \alpha = 1, \dots, s. \end{aligned} \quad (13)$$

La preuve, donnée en [appendix A](#), consiste seulement à projeter (12) sur chaque espace propre puis à factoriser les matrices G_α . Le système (13) est une caractérisation complète, pas une liste de formes choisies à l'avance.

4.1 Toutes les familles universelles contenues dans la condition

Le [table 2](#) donne les branches qui existent sans résoudre numériquement un cas particulier.

Table 2: Familles exactes sans MLP sous l'hypothèse liée symétrique.

Situation	Tous les équilibres ou familles immédiatement garantis
$V = 0$	toute configuration de $(\mathbb{S}^{d-1})^n$
Un jeton	toutes les sphères unités contenues dans les espaces propres de V
Consensus	$x_1 = \dots = x_n = u$ pour toute direction propre unitaire u
Une droite propre	tout motif $x_i \in \{u, -u\}$
Noyau de V	toute configuration contenue dans $\ker V$; des ajouts mixtes sont possibles si la sortie active s'annule
Un espace propre multiple	simplexes réguliers, polygones réguliers, hypercubes et autres orbites symétriques, avec multiplicités compatibles
Plusieurs espaces propres	branches mixtes, symétriques ou asymétriques, résolues par (13) ou (10)

Il n'existe donc pas de liste finie valable pour tout n, d, V : si $V = 0$, chaque point est un équilibre ; si une valeur propre est multiple, des familles continues apparaissent. La bonne notion de « tous les équilibres » est la condition constructive (13).

4.2 Classification entièrement explicite lorsque $\beta = 0$

À $\beta = 0$, les poids valent tous $1/n$. Posons

$$z = V \sum_{j=1}^n x_j.$$

Théorème 4.3 (Tous les équilibres à attention uniforme). *Pour une matrice V quelconque, une configuration est un équilibre si et seulement si l'une des deux situations suivantes se produit :*

1. $z = 0$; toute configuration telle que $V \sum_j x_j = 0$ convient ;
2. $z \neq 0$; tous les jetons valent u ou $-u$, leur somme signée est non nulle, et u est un vecteur propre réel de V associé à une valeur propre non nulle.

Cette classification montre à la fois la richesse et la fragilité du cas uniforme. Avec une matrice symétrique, il s'agit d'une dynamique d'énergie. Avec une matrice non symétrique, une rotation peut subsister même si les poids ne changent jamais.

4.3 Une famille mixte exacte à trois groupes

Soient $Vu = au$, $Vv = bv$, avec $u \perp v$. Prenons m copies de u , k copies de $qu + \sqrt{1-q^2}v$ et k copies de $qu - \sqrt{1-q^2}v$. Cette forme est un équilibre exactement lorsque

$$q \left[(a-b)e^{\beta[b+(a-b)q^2]} + (a+b)e^{\beta[-b+(a+b)q^2]} \right] + a \frac{m}{k} e^{\beta a q} = 0. \quad (14)$$

Cette seule équation produit des branches qui utilisent simultanément deux directions propres. Elle explique pourquoi « choisir une seule valeur propre » ne suffit pas à décrire toutes les destinations.

5 Quand un équilibre attire-t-il les trajectoires ?

La condition (8) dit où la dynamique peut s'arrêter. La stabilité dit ce qui se passe après une petite erreur de position.

Soit δx_i une petite variation perpendiculaire à x_i . Définissons

$$\delta s_{ij} = \delta x_i^\top S x_j + x_i^\top S \delta x_j, \quad (15)$$

$$\delta a_{ij} = \beta a_{ij} \left(\delta s_{ij} - \sum_k a_{ik} \delta s_{ik} \right), \quad (16)$$

$$\delta y_i = \sum_j a_{ij} V \delta x_j + \sum_j \delta a_{ij} V x_j. \quad (17)$$

À un équilibre $y_i = \lambda_i x_i$, la variation tangentielle du champ est

$$\delta \dot{x}_i = P_{x_i} \delta y_i - \lambda_i \delta x_i. \quad (18)$$

Ces lignes donnent la matrice de stabilité exacte pour toutes matrices S, V . L'équilibre attire localement si toutes ses valeurs propres tangentielles ont une partie réelle strictement négative. Une valeur nulle peut simplement correspondre à une famille continue obtenue par rotation ; elle doit alors être retirée avant de conclure.

5.1 Directions propres pures dans le cas lié symétrique

Pour un consensus $x_i = u$ sur une valeur propre λ_p , la condition locale est particulièrement simple :

$$\lambda_p > 0, \text{ et } \lambda_k < \lambda_p \quad (k \neq p). \quad (19)$$

Le consensus stable utilise donc la plus grande valeur propre positive simple.

Pour un partage équilibré entre u et $-u$, les seuils sont :

$$\lambda_p > 0 : \quad \lambda_k < \lambda_p \tanh(\beta \lambda_p) \quad \text{pour tout } k \neq p, \quad (20)$$

$$\lambda_p < 0 : \quad \lambda_p < \lambda_k < \lambda_p \tanh(\beta \lambda_p) \quad \text{pour tout } k \neq p. \quad (21)$$

Le second cas sélectionne nécessairement la valeur propre la plus négative. Les formules pour un partage déséquilibré sont données en [appendix C](#).

5.2 Un triangle stable qui n'est pas « polygonal » au sens d'Altafini

Pour $V = S = \text{Diag}(2, -3)$, $\beta = 1,5$ et trois jetons, la recherche de racines trouve la configuration d'angles, arrondie ici,

$$(0, 1,546889, 4,736296).$$

Son taux linéaire le moins contractant vaut $-0,9144$ et le résidu calculé avant arrondi est $1,3 \times 10^{-15}$. Surtout, les longueurs des trois sorties non normalisées valent environ 40,27, 269,79 et 269,79 : elles ne sont pas nulles. Elles pointent radialement. Ce triangle est donc stable et appartient à la classe « clustering » d'Altafini, pas à sa classe « polygonal ».

La recherche multi-départ de petits systèmes donne le [figure 1](#). Deux graines indépendantes retrouvent exactement les mêmes ensembles après retrait des permutations et du changement de signe global.




Figure 1: Catalogue sans MLP pour $V = S$ symétrique en dimension deux. Les spectres sont $(2, -3)$ avec $\beta = 1,5$, $(-0,4, -4)$ avec $\beta = 0,03$, et $(3, 2)$ avec $\beta = 1,5$. Les nombres au second niveau des étiquettes sont les nombres de jetons. La recherche numérique découvre les branches ; la complétude théorique vient de (13), pas du nombre de départs.

6 Cycles : trois objets qu'il faut séparer

6.1 Cycle court d'une couche finie

Un cycle de période p de la couche est une suite de p configurations distinctes qui revient exactement au départ après p applications de (4). Cet objet dépend de la force h .

Lemme 6.1 (Un nombre fixe de couches ne survit pas tel quel). *Si la couche satisfait $F_h(X) = X + hf(X) + O(h^2)$ et si p reste fixe lorsque $h \rightarrow 0$, alors toute limite d'un cycle de période p vérifie $f(X) = 0$.*

En effet, $F_h^p(X) = X + phf(X) + O(h^2)$. Un cycle de trois couches peut donc se contracter vers un équilibre quand on rend les couches faibles. Il ne prouve pas l'existence d'une boucle en temps continu.

6.2 Cycle continu

Un cycle continu est une boucle parcourue en un temps $T > 0$. Une couche de force h n'en parcourt qu'une fraction. Le nombre de couches par tour doit donc croître comme T/h . C'est la signature mesurée dans le [figure 4](#).

6.3 Rotation rigide et cycle interne

Si tous les produits scalaires $x_i^\top x_j$ restent constants pendant que l'ensemble tourne, la forme n'évolue pas : c'est une rotation rigide. Dans un cycle interne, au moins une distance entre jetons change puis revient. Cette seconde situation est plus forte.

Un exemple analytique montre déjà que l'attention sans MLP peut tourner. Prenons un seul jeton sur le cercle, $S = 0$ et

$$V = \omega \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}.$$

Alors $\dot{x} = Vx$ et le jeton tourne avec période $2\pi/|\omega|$. Cette rotation est neutre : elle ne prouve pas qu'une boucle attire les perturbations. L'expérience de la [section 8](#) établit précisément ce point plus difficile.

7 Pourquoi la symétrie interdit les cycles continus

Sous $S = V = V^\top$ et pour $\beta > 0$, définissons

$$E_\beta(X) = \frac{1}{2\beta} \sum_{i,j=1}^n \exp(\beta x_i^\top V x_j). \quad (22)$$

Si $Z_i = \sum_j \exp(\beta x_i^\top V x_j)$, un calcul direct donne

$$\frac{dE_\beta}{dt} = \sum_{i=1}^n Z_i \|\dot{x}_i\|^2 \geq 0. \quad (23)$$

La quantité augmente strictement dès qu'un jeton bouge. Une trajectoire fermée devrait revenir à sa valeur initiale de E_β , ce qui est impossible sauf si elle est déjà arrêtée. Ce mécanisme est la structure de gradient pondéré utilisée par Kuehn–Yoon [\[4\]](#).

À $\beta = 0$, la même conclusion vaut avec

$$\Phi(X) = \frac{1}{2n} \left(\sum_i x_i \right)^\top V \left(\sum_j x_j \right).$$

Lecture concrète. La symétrie importante n'est pas seulement « V est symétrique ». Il faut, pour cette preuve, que la matrice qui calcule les scores soit la même que celle qui transporte les valeurs : $S = V = V^\top$. Si S et V sont indépendantes, l'argument disparaît.

Sur le cercle à $\beta = 0$, l'écart à la réciprocité se voit exactement dans

$$\frac{\partial \dot{\theta}_i}{\partial \theta_j} - \frac{\partial \dot{\theta}_j}{\partial \theta_i} = \frac{1}{n} t_i^\top (V - V^\top) t_j. \quad (24)$$

La partie antisymétrique de V fournit donc une circulation. À $\beta > 0$, la normalisation ligne par ligne des poids ajoute des termes supplémentaires. Même lorsque les dérivées croisées ordinaires ne coïncident pas, le cas $S = V = V^\top$ reste sans cycle grâce à la métrique pondérée de (23). Ce détail évite de confondre « gradient euclidien » et « quantité monotone ».

8 Expérience centrale : un cycle stable produit par l'attention seule

8.1 Paramètres explicites

Le modèle utilise trois jetons sur le cercle, aucun MLP, et

$$S = \begin{pmatrix} 1,112495 & 1,768642 \\ -2,540753 & 3,294286 \end{pmatrix}, \quad V = \begin{pmatrix} -1,809502 & 1,419182 \\ -1,827949 & -3,611608 \end{pmatrix}, \quad (25)$$

avec $\beta = 1,110063$. L'audit mesure la profondeur avec une échelle $\rho = 0,551488$: son équation est $\dot{\theta}_i = \rho \sum_j a_{ij} t_i^\top V x_j$. Absorber ρ dans le temps ramène exactement à (6).

Ce modèle a été isolé par ablation d'un candidat provenant d'un écran plus large avec MLP. Après suppression de tous les paramètres MLP, le cycle reste présent. Le MLP seul, avec l'attention supprimée, converge au contraire vers un point fixe. Cette sélection du modèle doit être gardée en tête : elle démontre l'existence d'un cycle d'attention, pas sa fréquence dans une loi aléatoire de matrices.

8.2 La forme change pendant le tour

La réintégration indépendante par Runge–Kutta d'ordre quatre, avec pas 0,005, donne un temps de retour $T = 9,12$ en profondeur normalisée, soit 5,030 dans le temps de (6) après absorption de ρ . Le résidu de retour au quantile 90% est $1,56 \times 10^{-3}$ radian.

Les trois produits scalaires entre paires varient chacun de $-0,8002$ à $-0,0551$. La forme change donc fortement. Les poids envoyés par le jeton 1 vers les jetons 1, 2 et 3 parcourent respectivement les intervalles

$$[0,298, 0,982], \quad [0,015, 0,701], \quad [0,00018, 0,0341].$$

8.3 Pourquoi nous l'appelons stable

Sur une boucle autonome, une variation qui avance simplement la phase n'est ni contractée ni amplifiée : son taux théorique est zéro. Le spectre mesuré sur 2000 unités est

$$(-0,00273, -0,45676, -0,45937). \quad (26)$$

Le premier nombre est l'approximation finie du zéro de phase. Les deux autres sont nettement négatifs : les écarts perpendiculaires à la boucle se contractent.

Nous avons également ajouté 128 perturbations gaussiennes d'écart-type 0,08 autour d'un point du cycle. La médiane de la distance à toute la boucle passe de 0,0525 à 0,00194 ; son quantile 90% passe de 0,0938 à 0,00320. Le plateau final est du même ordre que l'espacement utilisé pour stocker la boucle de référence.




Figure 2: Cycle interne de l'attention seule. À gauche, les deux angles relatifs décrivent une boucle fermée ; une rotation rigide serait un point. À droite, sept phases d'un tour montrent les trois jetons sur le cercle. Les angles sont toujours pris modulo 2π .

8.4 Le tour demande bien un nombre de couches proportionnel à $1/h$

Nous avons rejoué la couche exacte (4) pour sept ratios, dont trois non dyadiques. Le [table 3](#) donne le meilleur retour complet.

Table 3: Retour du cycle de l'attention seule lorsque chaque couche est affaiblie. Le temps d'un tour est le nombre de couches multiplié par le ratio.

Ratio	Couches par tour	Temps du tour	Erreur angulaire maximale
1/16	138	8,625	$2,38 \times 10^{-2}$
1/31	275	8,871	$9,46 \times 10^{-3}$
1/64	576	9,000	$5,38 \times 10^{-3}$
1/127	1151	9,063	$5,43 \times 10^{-5}$
1/256	2328	9,094	$1,13 \times 10^{-3}$
1/509	4635	9,106	$7,42 \times 10^{-4}$
1/1024	9333	9,114	$1,09 \times 10^{-5}$

La pente de $\log(\text{couches par tour})$ en fonction de $\log(1/\text{ratio})$ vaut 1,012. Le temps du tour tend vers celui de l'équation continue, tandis que le nombre de couches diverge.

8.5 Ce que les autres ablations ont donné

Le [table 4](#) empêche une conclusion trop large. Les trois candidats chaotiques les plus étudiés ne restent pas chaotiques lorsque le MLP est supprimé ; ils convergent à un équilibre dans l'ablation attention seule.

Limite de la conclusion. Nous avons certifié l'existence d'un cycle interne stable produit par l'attention seule. Nous n'avons pas encore effectué un recensement aléatoire exhaustif dédié uniquement à l'attention générale. Nous ne concluons donc ni que ce cycle est unique, ni qu'il est fréquent. Aucune des ablations ciblées ne fournit à ce jour un attracteur chaotique d'attention seule.




Figure 3: Un tour du cycle. En haut, les produits scalaires entre jetons oscillent ; en bas, les poids de la première ligne d’attention oscillent eux aussi. La deuxième période visible dans les distances provient d’une permutation de rôle entre jetons au cours du retour complet des angles étiquetés.

Table 4: Résultat des ablations attention seule sur les représentants étudiés en détail.

Origine du représentant	Structure de l’attention	Résultat sans MLP
Cycle à trois jetons, indice 1323	S général, V général, $\beta > 0$	cycle interne stable
Chaos fort à trois jetons, indice 2612	S symétrique, V général, $\beta > 0$	consensus fixe
Chaos faible à trois jetons, indice 1051	$S = V = V^T$, $\beta > 0$	consensus fixe
Intermittence à quatre jetons, indice 3118	S symétrique, V général, $\beta = 0$	équilibre fixe

9 Comparaison exacte avec Altafini et Kuehn–Yoon

9.1 Ce qu’Altafini suppose réellement

Le modèle d’Altafini contient bien les matrices Q et K . Son analyse principale suppose :

$$V = V^T, \quad \lambda_1 > 0 \text{ simple et strictement dominante.} \quad (27)$$

Elle ne suppose pas $Q^T K$ symétrique. Sous ces conditions, Altafini prouve que les équilibres à sortie nulle qu’il appelle polygonaux sont instables. Il montre aussi que des consensus bipolaires et des équilibres de regroupement peuvent être stables et coexister.

9.2 Pourquoi nos résultats ne contredisent pas ce théorème

Il y a trois raisons indépendantes :

1. le triangle stable de la [section 5](#) a des sorties non nulles. Il est dans la classe « clustering » d’Altafini, que son théorème n’annonce pas instable ;




Figure 4: À gauche, contraction de 128 perturbations vers la boucle. La ligne est la médiane et la zone contient 80% des essais. À droite, nombre de couches par tour ; la pente proche de un est la signature d’un cycle continu, et non d’un artefact à trois ou quatre couches.

2. les branches négatives définies de Kuehn–Yoon n’ont aucune valeur propre positive et sortent donc de (27) ;
3. le cycle de (25) utilise un V non symétrique et n’est pas un équilibre. Il sort à la fois de l’hypothèse sur V et de la question « stabilité d’un équilibre polygonal ».

9.3 Ce que l’hypothèse de Kuehn–Yoon ajoute

Kuehn–Yoon imposent la relation plus forte

$$Q^T K = V = V^T.$$

Elle fournit la quantité monotone (22). Leur article établit des résultats globaux de sélection dans un cône lorsque la valeur propre positive dominante dépasse en module les autres, et pour deux jetons lorsque V est négative définie [4]. Notre caractérisation (13) complète la question différente « quels sont tous les points d’arrêt possibles ? », y compris les branches mixtes et les multiplicités, sans prétendre que chacun est atteint depuis une initialisation générique.

Table 5: Portée des trois analyses.

	Altafini	Kuehn–Yoon	Présent rapport
MLP	absent	absent	absent
Score $S = Q^T K$	général	égal à V	général, puis cas égal à V
Valeur V	symétrique, sommet positif simple	symétrique, spectres ciblés	générale ; classification complète si liée symétrique
Équilibres	quatre classes, seuils sur branches pures	sélection spectrale et stabilité pure	condition nécessaire et suffisante, réduction par groupes, système spectral–Gram
Cycles	cycle possible signalé si V perd la symétrie	interdits par l’énergie	cycle interne stable explicite sans MLP

10 Ce qui est nouveau, dit simplement

1. **Une seule équation couvre toutes les destinations.** Les consensus, les deux groupes opposés, les triangles, les formes asymétriques et les familles continues sont tous les cas de (8). La somme n'a pas besoin de s'annuler ; elle doit seulement être radiale.
2. **Le mot polygone ne décide pas de la stabilité.** Un dessin à plusieurs sommets peut être stable lorsque les sorties sont non nulles. L'affirmation « polygonal instable » d'Altafini concerne uniquement les sorties exactement nulles.
3. **Sans MLP ne veut pas dire sans mouvement durable.** L'égalité $Q^T K = V = V^T$ force l'arrêt, mais une tête générale peut entretenir seule un cycle où les distances et les poids d'attention oscillent.
4. **Nous savons distinguer une boucle réelle d'un tour de passe-passe de discrétisation.** Dans notre cycle, affaiblir une couche multiplie le nombre de couches nécessaires par le facteur inverse, tout en gardant le temps d'un tour proche de 9,12.
5. **Le résultat est une existence, pas encore une statistique universelle.** Un cycle stable est certifié ; aucun chaos sans MLP ne l'est. La fréquence de ces cycles pour des matrices aléatoires reste une expérience fondamentale à faire.

11 Conclusion

Le système sans MLP est déjà assez riche pour avoir plusieurs destinations stables et, si la réciprocité est brisée, une oscillation interne stable. La frontière théorique est simple. Lorsque la même matrice symétrique calcule les scores et transporte les valeurs, une quantité augmente à chaque mouvement : les jetons doivent finir par s'arrêter. Quand les deux rôles sont séparés, cette barrière disparaît ; les sommes reçues peuvent se relancer mutuellement autour d'une boucle.

La condition finale à retenir est (8). Elle est exacte dans toute dimension. Elle dit ce qu'il faut résoudre pour énumérer les équilibres, ce qu'il faut différencier pour tester leur stabilité, et pourquoi une forme à plusieurs sommets peut être stable sans contredire Altafini. Le cycle explicite montre ensuite que les équilibres ne sont pas toute l'histoire dès que S et V ne sont plus liés par la symétrie forte de Kuehn–Yoon.

A Preuves complémentaires

A.1 Preuve du théorème spectral–Gram

Dans une base propre de V , écrivons $X = C_1 \oplus \dots \oplus C_s$. L'équation $RXV = MX$ projetée sur l'espace de valeur propre λ_α^* devient

$$(\lambda_\alpha^* R - M)C_\alpha = 0.$$

En multipliant à droite par C_α^T , on obtient $(\lambda_\alpha^* R - M)G_\alpha = 0$. Les identités sur H et les diagonales suivent de la décomposition orthogonale.

Réciproquement, factorisons toute solution positive $G_\alpha = C_\alpha C_\alpha^T$ avec au plus m_α colonnes. L'image de G_α est la même que celle de C_α ; l'équation sur G_α implique donc l'équation sur C_α . En plaçant ces facteurs dans des espaces propres orthogonaux, on reconstruit X et $RXV = MX$. Deux factorisations du même G_α diffèrent par une rotation interne à l'espace propre, ce qui prouve l'énoncé modulo ces rotations.

A.2 Preuve de la classification à $\beta = 0$

À attention uniforme, tous les champs ont la forme $P_{x_i}z/n$ avec $z = V \sum_j x_j$. Si $z = 0$, la configuration est arrêtée. Sinon, chaque x_i doit être parallèle à z , donc $x_i \in \{u, -u\}$ avec $u = z/\|z\|$. La somme vaut cu . Puis $z = cVu$ est parallèle à u , donc u est propre. Comme $z \neq 0$, c et la valeur propre associée sont non nuls. La réciproque est immédiate.

A.3 Absence de sorties nulles lorsque V est positive définie

Sous $S = V \succ 0$, regroupons les q positions distinctes w_a . La matrice

$$\mathcal{R}_{ab} = \exp\left(\beta \left\langle V^{1/2}w_a, V^{1/2}w_b \right\rangle\right)$$

est strictement positive définie pour des points distincts. Elle est donc inversible. La condition de sortie nulle s'écrit $\mathcal{R} \text{Diag}(r_1, \dots, r_q)WV = 0$. Puisque $\mathcal{R}$, $\text{Diag}(r_1, \dots, r_q)$ et V sont inversibles, cette égalité imposerait $W = 0$, ce qui contredit la norme un de ses lignes. Les équilibres à plusieurs sommets qui restent possibles ont donc nécessairement une sortie radiale non nulle.

B Jacobienne exacte sur le cercle

Cette annexe donne une formule directement programmable. Posons

$$g_{ij} = t_i^\top V x_j, \text{quad}s_{ij} = x_i^\top S x_j, \text{quad}f_i = \sum_j a_{ij} g_{ij}.$$

Pour l'angle θ_k ,

$$D_k s_{ij} = \mathbf{1}_{i=k} t_i^\top S x_j + \mathbf{1}_{j=k} x_i^\top S t_j, \quad (28)$$

$$D_k g_{ij} = -\mathbf{1}_{i=k} x_i^\top V x_j + \mathbf{1}_{j=k} t_i^\top V t_j. \quad (29)$$

La dérivée du softmax donne alors

$$J_{ik} = \sum_j a_{ij} \left[D_k g_{ij} + \beta g_{ij} \left(D_k s_{ij} - \sum_\ell a_{i\ell} D_k s_{i\ell} \right) \right]. \quad (30)$$

À un équilibre, les parties réelles des valeurs propres de J décident de la stabilité. Pour la couche finie, on calcule directement la Jacobienne de F_h ; ses valeurs propres doivent avoir un module inférieur à un. Pour h petit, un taux continu λ donne un multiplicateur de couche $1 + h\lambda + O(h^2)$.

C Partage bipolaire déséquilibré

Soit n_+ le nombre de $+u$, n_- le nombre de $-u$ et $r = n_+/n_-$. Pour une valeur propre λ_p , définissons

$$c = e^{2\beta\lambda_p}, \quad \sigma(c, r) = \frac{(c-r)(cr-1)}{r(c^2-1)}.$$

Si $\lambda_p > 0$, le partage est localement stable exactement lorsque

$$\lambda_p > \frac{|\log r|}{2\beta}, \quad \lambda_k < \lambda_p \sigma(c, r) \quad (k \neq p).$$

Si $\lambda_p < 0$, la condition est

$$\lambda_p < -\frac{|\log r|}{2\beta}, \quad \lambda_p < \lambda_k < \lambda_p \sigma(c, r) \quad (k \neq p).$$

Pour $r = 1$, $\sigma = \tanh(\beta\lambda_p)$ et l'on retrouve (20)–(21).

D Reproductibilité et traçabilité des affirmations

Les fichiers principaux sont :

- `experiments/spectral_self_attention/non_mlp_report_experiments.py` pour la réintégration, les perturbations, le test en profondeur et les figures ;
- `data/spectral_self_attention/non_mlp_report_results.json` pour tous les nombres affichés dans la section du cycle ;
- `data/spectral_self_attention/continuous_ode_f4_p3_cycle_attention_only.json` pour l'ablation initiale ;
- `data/spectral_self_attention/continuous_lyapunov_spectrum_f4_p3_cycle_attention_only_relaxed2.json` pour le spectre long ;
- `data/spectral_self_attention/equilibria/planar_small_systems.csv` et `search_saturation.csv` pour le catalogue de petits systèmes ;
- `experiments/spectral_self_attention/equilibrium_catalogue.py` et `run_equilibrium_catalogue.py` pour les racines d'équilibre.

Depuis la racine du dépôt, la commande

```
.venv/bin/python \
    experiments/spectral_self_attention/non_mlp_report_experiments.py
```

recrée les quatre figures et le résumé JSON. Les matrices de (25), les graines aléatoires, les pas, les durées et les seuils sont stockés dans ces fichiers.

Table 6: Statut exact des principales affirmations.

Affirmation	Statut
Condition (8)	théorème algébrique, nécessaire et suffisant
Système (13)	théorème, complet modulo rotations des espaces propres
Pas de cycle si $S = V = V^T$	conséquence exacte de (23)
Triangle stable affiché	racine numérique, résidu $< 1,3 \times 10^{-15}$, Jacobienne contractante
Cycle général sans MLP	certificat numérique : retour, spectre, perturbations et loi en profondeur
Absence de chaos sans MLP	non établie ; seulement constatée sur les ablations ciblées
Fréquence des cycles aléatoires	non mesurée dans un recensement dédié

Références

- [1] Claudio Altafini. Multistability of self-attention dynamics in transformers. *arXiv preprint arXiv:2511.11553*, 2025.
- [2] Borjan Geshkovski, Clément Letrouit, Yury Polyanskiy, and Philippe Rigollet. The emergence of clusters in self-attention dynamics. In *Advances in Neural Information Processing Systems*, volume 36, pages 57026–57037, 2023.
- [3] Borjan Geshkovski, Clément Letrouit, Yury Polyanskiy, and Philippe Rigollet. A mathematical perspective on transformers. *Bulletin of the American Mathematical Society*, 62(3):427–479, 2025.
- [4] Christian Kuehn and Jaeyoung Yoon. Spectral selection in symmetric self-attention dynamics. *arXiv preprint arXiv:2604.26085*, 2026.
- [5] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [6] Biao Zhang and Rico Sennrich. Root mean square layer normalization. In *Advances in Neural Information Processing Systems*, volume 32, 2019.